

分类号
UDC

学校代码 10590
密级

硕士学位论文

基于无人机遥感的可见光与多光谱图像 融合的陆地油田溢油检测算法研究

学位申请人姓名 郑楚川

学位申请人学号 2310273066

专业（领域）名称 计算机技术

学 位 类 别 工程

学院（部、研究院） 计算机与软件学院

导 师 姓 名 梁正平

二〇二六年一月

深圳大学

学位论文原创性声明

本人郑重声明：所呈交的学位论文是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本声明的法律后果由本人承担。

论文作者签名：日期：年月日

深圳大学

学位论文使用授权说明

本学位论文作者完全了解深圳大学关于收集、保存、使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属深圳大学。学校有权保留学位论文并向国家主管部门或其他机构送交论文的电子版和纸质版，允许论文被查阅和借阅。本人授权深圳大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

（涉密学位论文在解密后适用本授权书）

论文作者签名：导师签名：

日期：年月日日期：年月日

摘要

基于无人机平台的可见光影像检测方法在油田巡检中得到了初步应用。然而,单一可见光成像方式对光照条件高度敏感,在阴影遮挡、土壤颜色相近或地表湿度变化等复杂场景下,原油泄漏区域在可见光图像中的判别特征不明显,何在复杂环境下提升检测精度与鲁棒性仍是亟待解决的问题。针对上述挑战,本文主要开展了以下研究工作:

关键词: 目标检测, 多光谱, 多模态融合, 图像配准

ABSTRACT

XX
XX
XX
XX.....

XX
XX.....

.....

Keywords:XXXXXXXX,XXXXXXX,XXXXXXXXXXXX,XXXXXXXXXXXX,XXX
XXXXXX

目录

摘要.....	I
ABSTRACT.....	II
目录.....	III
符号和缩略语说明	5
第一章 绪论 公式章 1 节 1	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 基于可见光图像的目标检测	2
1.2.2 基于多光谱的目标检测研究现状	4
1.2.3 溢油检测研究现状	7
1.3 论文研究内容	10
1.4 论文组织结构	10
第二章 相关理论和技术基础	11
2.1 多光谱成像原理	11
2.2 深度学习相关理论	12
2.2.1 卷积神经网络	12
2.2.2 注意力机制	14
2.3 目标检测网络	17
2.3.1 DETR 网络	17
2.3.2 RT-DETR	18
2.4 多光谱目标检测网络	20
2.4.1 基于像素级融合的多光谱目标检测网络结构	20
2.4.2 基于特征级融合的多光谱目标检测网络结构	21
2.4.3 基于决策级融合的多光谱目标检测网络结构	22
2.5 目标检测评估指标	23
2.6 本章小节	25
第三章 油田溢油数据集构建与预处理	26
3.1 引言	26
3.2 研究区域	26
3.3 数据采集设备与多光谱成像系统	27
3.3.1 成像设备与无人机平台配置	27
3.3.2 多光谱成像系统结构与成像特点	28

3.4 数据采集设置	29
3.5 原始数据预处理与标注	30
3.6 数据分析	32
3.7 本章小节	33
第四章 基于感受野增强和跨尺度融合的目标检测算法.....	34
4.1 引言	34
4.2 算法设计	34
4.3 实验设计	34
4.4 实验结果与分析	34
4.5 本章小节	34
第五章 可见光与多光谱融合的端到端目标检测.....	35
5.1 引言	35
5.2 算法设计	36
5.2.1 规范参考引导的分组对齐方法(Canonical Reference Guided Groupwise Alignment)	37
5.2.2 自适应采样多光谱融合方法(Adaptive Sampling Multispectral Fusion)	40
5.3 实验设计	45
5.3.1 实验数据集.....	45
5.3.2 评价指标.....	46
8.1.1 实验基本环境.....	49
8.2 实验结果与分析	49
8.2.1 XXXXXXXX.....	49
8.3 本章小节	51
第九章 总结与展望	52
参考文献.....	53
附录 AXXXXXX	57
A. 1XXXXXXX.....	57
A. 2XXXXXXX.....	57
致谢.....	58
攻读硕士学位期间的科研成果	59

符号和缩略语说明

DFT	密度泛函理论(DensityFunctionalTheory)
HPLC	高效液相色谱(HighPerformanceLiquidChromatography)
LC-MS	液相色谱-质谱联用(Liquidchromatography-MassSpectrum)
SCRf	自洽反应场(Self-ConsistentReactionField)
TIC	总离子浓度(TotalIonContent)
ZPE	零点振动能(ZeroVibrationEnergy)
E _a	化学反应的活化能(ActivationEnergy)
$\Delta G^\ddagger$	活化自由能(ActivationFreeEnergy)
ν_i	虚频(ImaginaryFrequency)

第一章 绪论

1.1 研究背景及意义

石油溢油是指液态石油烃在石油勘探、生产、运输、储存以及使用过程中由于人为活动、设备失效或意外事故等原因溢出工程系统并进入自然环境的事件^[1]。溢油事件主要发生在海洋、陆地水体及土壤表层等环境中^[2]，这种溢出不仅可能造成能源浪费，还会引起环境污染、生态破坏及安全隐患，对周边生态系统和人类生活构成严重威胁。因此其监测与快速响应在环境与安全领域具有重要研究价值。

在石油产业链的各个环节中，泄漏源具体包括油田现场管道破裂、油井抽油管断裂、采油树泄漏以及储运设施故障等^[3]。这些泄漏事件经常导致油品或原油向地面、土壤、水体等环境介质扩散，从而造成严重的油污污染问题。针对油污泄漏的高效监测与定位是油田生产和环境保护的核心问题。

以大庆油田为代表的陆上油田区域分布范围广、地表环境复杂，漏油区域往往呈现出形态不规则、尺度变化大的特点，且易与周围裸土、植被、积水等地物产生光谱与外观上的混淆，给人工巡检和传统监测手段带来了较大挑战^[4]。随着无人机（Unmanned Aerial Vehicle, UAV）技术快速发展，基于无人机的多光谱遥感成为陆地溢油检测的重要技术手段。无人机平台由于具备机动性强、部署灵活、成本低等优势^[5]，可搭载多光谱传感器快速获取事故区域高分辨率影像，为溢油检测提供时空分辨率较高的数据资源。多光谱遥感技术通过不同波段信息的协同分析可以增强油污目标与背景的分离能力。

然而，无人机多光谱溢油检测仍面临如下挑战：一方面，不同光谱波段图像之间存在配准误差和几何畸变，这会影响多光谱信息的正确融合；另一方面，传统基于规则阈值或经验特征的检测方法对于复杂环境下的溢油目标区分能力较弱，难以满足实时性与高准确率的需求。此外，针对无人机平台存在计算资源受限的特点，需要设计轻量化、高效且具有良泛化能力的检测模型。

传统的遥感溢油检测方法依赖于卫星影像或固定传感器数据，但这些方法通常受云雾天气、时间重访周期长、分辨率不足等限制，难以实现快速响应。相比之下，无人机多光谱遥感在临近事件发生区域可提供细粒度的空间信息，提高检

测的时效性与准确性。近年来，深度学习技术尤其是基于卷积神经网络（CNN）和检测模型的发展，为图像级自动检测提供了新的解决路径，并逐渐成为油污遥感检测领域的主流方法。

本文针对陆地油田复杂环境下无人机多光谱溢油检测面临的图像配准误差、多模态特征利用不足以及实时性受限等问题，开展基于深度学习的多光谱溢油检测方法研究。

现有无人机溢油检测方法多采用单一模态或简单特征拼接方式对多光谱信息进行融合，难以充分挖掘不同光谱通道在油污识别中的互补特性；同时，一些高精度检测模型结构复杂、计算开销较大，在无人机端或近端计算平台上难以满足实时检测需求。

针对上述问题，本文以高效端到端目标检测框架为基础，构建面向无人机多光谱遥感场景的溢油检测网络。通过分别对可见光与多光谱信息进行特征建模，并在高层语义空间引入跨模态特征融合机制，实现对油污目标多尺度、多光谱特征的协同表达。在保证检测精度的同时，兼顾模型的计算效率与实时性需求，使其更适合部署于无人机巡检和近实时监测场景。

本文研究在工程应用层面可为陆地油田溢油事件提供高效、自动化的监测手段，有助于降低人工巡检成本、提升事故响应速度；在理论与方法层面，探索了多光谱信息在端到端目标检测框架下的有效融合方式，对无人机遥感目标检测及多模态视觉理解研究具有一定的参考价值。

1.2 国内外研究现状

1.2.1 基于可见光图像的目标检测

1.2.1.1 传统单模态目标检测方法

随着计算机视觉技术的发展，基于可见光图像的目标检测已成为计算机视觉领域的重要研究方向，并在安防监控^[6]、自动驾驶^[7]和遥感影像^[8,9]等应用中得到广泛应用。可见光目标检测通常以 RGB 图像为主要数据来源，通过分析目标的形状、纹理和结构特征实现定位与识别。传统目标检测方法普遍遵循“候选区域生成—特征提取—分类判别”的三阶段处理流程，其整体框架建立在人工特征设计与传统机器学习分类器之上^[10]。在检测过程中，首先通过滑动窗口、多尺度搜

索或图像分割等策略在图像中生成一系列感兴趣区域（Region of Interest, ROI），并以候选框形式表示可能包含目标的区域^[11]；随后，对候选区域进行特征提取，利用 SIFT^[12]、LBP^[13]、HOG^[14]等人工设计的特征描述子，将图像区域映射为具有判别能力的特征向量；最后，将特征向量输入支持向量机（SVM）^[15]或 AdaBoost^[16]等分类器，对候选框内是否包含目标进行分类或概率估计。尽管该类方法在早期可见光目标检测任务中取得了一定成效，但其特征表达高度依赖人工经验，对光照变化、遮挡和复杂背景等情况适应性较弱，整体鲁棒性和泛化能力有限，难以满足复杂实际场景下对检测精度与稳定性的更高要求。

1.2.1.2 基于深度学习的单模态目标检测方法

卷积神经网络（Convolutional Neural Network, CNN）的提出与发展为目标检测技术带来了重要突破，其强大的特征自动学习能力有效克服了传统方法对手工特征设计的依赖，显著推动了深度学习在目标检测领域的广泛应用。2012 年，AlexNet^[17] 在 ImageNet^[18]大规模图像分类挑战赛中取得突破性成果，深度学习方法在可见光图像理解任务中的优势开始显现。在此背景下，研究者逐步将卷积神经网络引入基于可见光图像的目标检测领域，推动了检测模型由传统方法向深度学习方法的转变。

基于深度学习的可见光目标检测方法通常可分为两阶段方法和一阶段方法两大类。两阶段目标检测方法以 R-CNN^[19]系列为代表，其基本思想是从可见光图像中生成候选区域，再对候选区域进行目标分类与位置回归。R-CNN 方法通过传统区域提议算法生成候选框，并利用 CNN 对候选区域进行特征提取和分类回归，虽然在检测精度方面取得了显著提升，但其训练与推理过程较为复杂，计算开销较大。为此，Fast R-CNN^[20]与 Faster R-CNN^[21]通过特征共享与区域提议网络（Region Proposal Network, RPN）实现了端到端训练，在保持较高检测精度的同时显著提升了检测效率。在此基础上，Mask R-CNN^[22]则在 Faster R-CNN 框架上引入实例分割分支，增强了对目标区域的精细化表征能力。总体而言，两阶段方法在复杂可见光场景下具有较高检测精度，但其计算复杂度较高，在实时性要求较强的应用场景中存在一定局限。

为满足实时检测需求，研究者提出了一阶段可见光目标检测方法。该类方法直接基于输入的可见光图像对目标类别和边界框进行回归预测，不再依赖候选区

域生成过程,从而在检测速度和计算效率方面具有明显优势。YOLO (You Only Look Once) 系列算法^[23]通过端到端的预测方式实现了较高的实时检测性能; SSD (Single Shot MultiBox Detector) 算法^[24]利用多尺度特征图对不同尺度目标进行检测,在检测速度与精度之间取得了一定平衡。随着网络结构和训练策略的不断优化,一阶段方法逐渐成为基于可见光目标检测领域的重要研究方向和主流解决方案。

近年来,Transformer^[25]架构被引入可见光目标检测任务中,进一步推动了检测模型的发展。其中 Vision Transformer (ViT)^[26]首次验证了纯 Transformer 结构在图像特征建模中的可行性。在此基础上,Transformer 被进一步引入可见光目标检测任务中,推动了检测模型的发展。DETR^[27]及其改进模型通过自注意力机制实现全局特征建模,摆脱了传统锚框与非极大值抑制的依赖。Deformable DETR^[28]通过引入可变形注意力机制,有效降低了计算复杂度并加快了模型收敛速度; Conditional DETR^[29]通过条件查询机制提高了目标匹配效率,缓解了原始 DETR 收敛缓慢的问题。此外, DAB-DETR^[30]和 RT-DETR^[31]等方法针对目标定位与实时检测需求对 Transformer 架构进行了优化,其中 RT-DETR 系列在保持端到端检测特性的同时,在推理速度与检测精度之间取得了较好平衡,使 Transformer 架构在实时可见光目标检测任务中具备了更强的工程应用潜力。

尽管上述基于深度学习的可见光目标检测方法在检测精度和效率方面取得了显著进展,但其性能仍高度依赖于可见光图像的成像质量。在复杂环境条件下,如光照变化剧烈、阴影干扰明显、目标存在遮挡或目标与背景在可见光波段下外观相似时,检测模型仍容易产生误检与漏检^[32]。此外,单一可见光图像仅包含有限的光谱信息,难以充分刻画不同地物之间的本质差异,限制了模型在复杂场景中的判别能力。因此,单一依赖可见光信息的目标检测方法在复杂环境下仍面临性能瓶颈,如何突破可见光图像信息受限所带来的固有不足,成为当前目标检测领域亟需解决的重要问题之一。

1.2.2 基于多光谱的目标检测研究现状

尽管近年来单模态可见光目标检测方法通过网络结构优化、特征增强及训练策略改进,在一定程度上提升了复杂环境下的检测性能,但其本质仍受限于可见光图像的信息维度单一。当目标遭受严重遮挡、阴影干扰,或与背景在可见光波

段下呈现高度相似外观时，检测模型难以提取稳定可靠的判别特征，即使采用更复杂网络也难以突破性能瓶颈。

为克服可见光成像的固有局限，研究者开始引入多波段信息以增强检测鲁棒性。多光谱图像可在近红外或其他波段捕捉目标与背景的差异特性，不同光谱通道的成像机理互补性有助于有效缓解光照变化、阴影遮挡及背景相似性等干扰因素的影响。将多光谱信息融入目标检测任务，已成为提升全天候、复杂场景检测能力的重要研究方向。

多光谱目标检测研究的系统化探索始于多光谱数据获取与基准数据集的构建。2015 年，Hwang 等人^[33]设计了一种用于 RGB 与红外图像像素级对齐的双模态采集设备，并基于该设备构建了首个大规模多光谱行人检测数据集 KAIST，为后续算法的统一评估提供了标准化平台，标志着该领域进入可复现、可量化阶段。

早期研究主要围绕多光谱信息的融合方式展开。2016 年，Wagner 等人^[34]提出了一种基于卷积神经网络的多光谱行人检测方法，分别设计了早期融合与晚期融合两种网络架构，并通过实验验证了在该任务中晚期融合策略在检测精度上更具优势。同年，Liu 等人^[35]系统地比较了早期融合、中期融合、晚期融合及决策级融合四种多光谱融合架构，实验结果表明，中期融合在低层纹理信息与高层语义信息之间取得了较好的平衡，为后续特征级融合方法的广泛采用提供了重要依据。

随着目标检测网络结构的不断演进，研究者开始将多光谱信息引入经典检测框架中。Konig 等人^[36]基于 Faster R-CNN 结构，提出了一种融合可见光与红外信息的全卷积区域提议网络，通过在候选区域生成阶段引入多光谱特征，提升了弱光照与远距离行人检测性能，尽管训练依赖多阶段微调，计算复杂度较高。为进一步提升多光谱目标检测的语义表达能力，Li 等人^[37]提出了 MSDS-RCNN 模型，将语义分割任务与行人检测任务进行联合建模，通过联合语义分割与检测任务共享特征表示，强化目标区域语义约束，有效缓解复杂背景下的语义不一致问题，为多任务学习在多光谱检测中的应用开辟新思路。

近年来，注意力机制的引入显著提升了跨模态特征交互能力。Zhang 等人^[38]提出了一种基于双流架构的多光谱检测网络，分别对可见光和红外图像进行特征提取，并通过交叉注意力机制实现跨模态特征建模，在中间融合层自适应地调整

不同模态特征的重要性，从而有效保留互补信息并抑制冲突特征。该方法在小尺度目标检测和复杂背景场景下表现出更强的鲁棒性。

针对光照变化对多光谱检测性能的影响，Yang 等人^[39]提出了 BAANet 模型，在网络中分阶段引入基于注意力的模态自适应门控机制（BAA-Gate），对可见光与红外特征进行动态校准，并结合基于光照条件的权重分配策略，使模型能够根据环境变化自适应调整不同模态的贡献比例，从而提升了全天候条件下的检测稳定性。尽管该模型在鲁棒性方面表现优异，但其网络结构较为复杂，对计算资源提出了更高要求。

针对 RGB-红外（RGB-IR）检测中常见的模态失准（miscalibration）和融合不精确（fusion imprecision）问题，近期 Transformer 方法取得突破。Yuan 等人^[40]提出 C²Former，通过 Inter-modality Cross-Attention（ICA）模块学习 RGB 与 IR 间的跨注意力关系，同时实现特征校准与互补融合；并引入 Adaptive Feature Sampling（AFS）模块降低全局注意力计算成本。该方法可嵌入现有单阶段/两阶段检测器，在 DroneVehicle 和 KAIST 数据集上验证了其在弱对齐与互补信息利用方面的优越性。

在高光谱目标检测方向，研究进一步聚焦光谱-空间信息的统一聚合与高效提取。Fang 等人^[41]提出 S²ADet 检测器，通过高光谱信息解耦（HID）模块（波段选择+PCA）减少冗余，并采用双流网络实现光谱与空间特征交互融合，显著提升类内/类间相似场景下的检测性能。Li 等人^[42]则针对通道冗余与信息丢失问题，设计边缘保持降维（EPDR）模块保留关键光谱与边缘纹理，结合空间特征增强模块（SFEM）融合 CNN 多尺度局部提取与 Visual Mamba 全局依赖建模，实现高效多尺度空间感知，在 HOD 数据集上超越基准方法。

现有多光谱目标检测研究证明，通过合理设计融合策略与跨模态建模，可充分利用不同光谱的互补特性，在弱光照、复杂背景及目标外观相似场景下显著提升检测性能。然而，该领域仍面临数据获取成本高、跨模态配准误差难以根除、模型复杂度与实时性矛盾等挑战。未来，如何在保障精度的前提下开发高效、轻量化的多光谱融合检测模型，特别是适用于无人机遥感场景的端到端算法，仍是核心研究方向。

1.2.3 溢油检测研究现状

溢油事件广泛发生于海洋与陆地环境中，具有突发性强、扩散速度快、生态危害严重等特点。早期溢油监测主要依赖人工巡查或航空目视调查，但该方法存在成本高、效率低、覆盖范围有限等问题，难以满足大范围、快速响应的监测需求^[9]。随着遥感技术的发展，基于遥感影像的溢油检测方法逐渐成为环境监测领域的重要研究方向，其中以合成孔径雷达（Synthetic Aperture Radar, SAR）、激光诱导荧光 LIF-LiDAR 以及光学遥感（多光谱/高光谱）技术为代表的研究最为典型。

在海洋溢油检测领域，SAR 由于具备全天时、全天候和大范围成像能力，被认为是最核心的技术手段之一。Fingas 和 Brown^[9]系统综述了 SAR 在海洋溢油监测中的应用，指出油膜可通过抑制海面微波散射而在 SAR 图像中呈现为暗斑区域，从而实现对大尺度溢油分布的有效识别。Ma 等人^[43]和 Yang 等人^[44]指出，在低风速或平静海面条件下，SAR 图像中易出现与溢油形态相似的“类油膜”现象，导致误检率显著上升。对于陆地小尺度、背景复杂的溢油场景，SAR 的空间分辨率和对地表纹理的敏感性仍存在明显局限。

除 SAR 外，激光诱导荧光 LIF-LiDAR 作为一种主动遥感技术，也被用于溢油检测。Lennon 等人^[52]最早将 LIF 技术应用于溢油监测，证明其对石油类物质具有较高的灵敏度，能够实现长距离、高精度探测。Shao 等人^[53]和 Yin 等人^[54]进一步改进了 LIF-LiDAR 系统性能，实现了对水面溢油的高精度探测。然而，Sun 等人^[55]指出，当无人机搭载 LIF LiDAR 在较高飞行高度作业时，荧光信号易受到太阳背景噪声干扰，信噪比显著下降，限制了其在常规陆地巡检场景中的推广应用。

相比上述两种方式，光学遥感（尤其是基于可见光与近红外波段的多光谱和高光谱技术）能够提供更加直观和精细的溢油信息，基于可见光与近红外波段的光学遥感影像在溢油边界刻画和形态识别方面具有优势。Yang 等人^[45]利用高光谱遥感数据对不同类型溢油进行分析，证明高光谱技术在油品识别、油膜厚度估

计及生态影响评估方面具有独特优势。Zhang 等人^[46]进一步指出，高光谱遥感在复杂海洋环境下能够有效区分溢油与背景水体。Tadmor 等人^[50]分析了石油溢油在可见光和近红外波段的反射特性差异，为多光谱溢油检测提供了理论依据。

然而，由于高光谱数据体量大、处理流程复杂、计算成本高，且易受光照、天气和地表浑浊度干扰，该类方法在大范围快速筛查和应急响应中的应用仍受到一定限制。相比之下，多光谱成像在平衡分辨率、数据量和光谱信息方面更具实用性，尤其适合无人机平台部署。Sun 等人^[49]将多光谱相机集成于无人机平台，用于溢油检测研究，结果表明多波段信息能够显著提升溢油与背景水体的区分能力。Barabanova 等人^[51]利用多光谱遥感数据实现了小尺度溢油的精确定位，验证了该方法在复杂近岸环境中的应用潜力。

现有研究主要集中于海洋溢油监测。海洋环境背景相对单一，溢油尺度通常较大，因此以 SAR 和星载光学遥感为主的检测体系已较为成熟。Yang 等人^[43]通过融合 SAR 与光学影像信息，提高了海洋溢油检测的准确性和稳定性。然而，对于小尺度、局部溢油事件，该类方法仍受制于空间分辨率和时间分辨率，难以实现精细化定位。

相比之下，目前针对陆地油田及近岸区域溢油的遥感检测研究相对较少，现有的文献主要聚焦于海洋场景，而陆地环境下的相关论文数量有限且多处于起步阶段。陆地溢油通常具有面积小、形态不规则、背景复杂等特点，易与裸土、植被、水渍等地物产生光谱和外观混淆，导致传统星载遥感方法在空间分辨率和时效性方面难以满足精细化监测需求。随着无人机（UAV）技术的发展，研究者逐渐将溢油检测平台由卫星扩展至航空与无人机系统。Hu 等人^[47]指出，无人机平台具有部署灵活、飞行高度低、成像分辨率高等优势，能够在事故发生后快速获取高质量影像。Nahiyoon 等人^[48]进一步验证了无人机在应急溢油监测中的高效性和可操作性。

在无人机溢油检测研究中，多光谱成像技术逐渐成为重要发展方向。Xing 等人^[2024]针对陆地表面油溢初期小面积、易与土壤和湖泊混杂的特点，提出了一种基于小样本的 Res-SU_{net} 分割网络。该方法利用大庆油田地表溢油区域的多光谱图像（54 组×6 个光谱通道），通过反射率光谱特征进行预处理，按 3:2:2 比例划分数据集。Res-SU_{net} 在传统 U-Net 基础上引入残差连接，提升特征提取能力与梯度传播稳定性。实验结果显示，该模型在小样本条件下分割性能优于标

准 U-Net 和改进型 S-UNet, 指标分别提升 1.17% 和 1.39%。其轻量级设计、快速推理特性特别适用于油溢初期快速识别, 为减少经济损失和环境污染提供了实用工具。该工作突显了小样本学习在陆地高分辨率分割中的潜力, 但对多光谱通道间深度融合机制的探索仍较为初步。

随着人工智能技术的发展, 深度学习方法逐渐被引入溢油检测领域。Nasayreh 等人^[56]基于 Faster R-CNN 构建了溢油目标检测模型, 实现了溢油区域的自动识别, 但模型性能对训练数据标注质量高度敏感。Rutoh 等人^[57]采用 U-Net 及其变体进行溢油区域分割, 在规则形态溢油检测中取得较好效果, 但在油水混合区域及多尺度溢油场景下的适应性仍有限。为提升模型对不同尺度溢油特征的表征能力, Chen 等人^[58]、Tao 等人^[59]和 Wang 等人^[60]引入多尺度卷积结构, 提高了复杂场景下的检测精度。Fang 等人^[61]和 Xu 等人^[62]进一步结合 SimAM 注意力机制, 在不显著增加模型参数量的前提下增强了关键特征表达能力, 但在实时性和跨场景泛化性能方面仍有改进空间。Zhang 等人^[2025] 针对内陆湖泊油溢场景的复杂性（水流扰动、植被遮挡、油膜扩散）, 基于 YOLOv11 架构提出 YOLO-ADHF-SimAM 模型。该方法自研 ADHF 模块, 通过自适应扩散式跨尺度特征聚合策略, 动态平衡多尺度特征; 同时集成 SimAM 无参数注意力机制, 进一步增强关键特征提取并抑制背景干扰。作者使用大庆油田湖泊溢油现场采集的 623 张多光谱图像构建数据集。相比基线 YOLOv11, 改进模型精度提升 1.8%, 召回率提升 6%, mAP@50 提升 3.3%, mAP@50:95 提升 2%, 展现出更强的鲁棒性和实时性。该工作首次将自适应多尺度融合与注意力机制深度结合应用于 UAV 多光谱油溢检测, 为复杂内陆水域环境提供了高效实时解决方案。然而, 在实时性和跨场景泛化性能方面, 现有方法仍有改进空间。

综上所述, 现有研究在海洋溢油检测领域已形成以 SAR 为主、LIDAR 为补充、光学遥感（尤其是多光谱）为精细化方向的较为成熟体系, 但陆地及内陆油田溢油的精细化监测仍面临背景复杂、尺度小、时效性要求高等挑战。尽管无人机多光谱遥感结合深度学习取得显著进展, 但陆地相关论文数量有限, 且可见光与多光谱图像的深度融合、跨模态对齐以及极端条件下鲁棒性等方面仍存在明显不足。这为本文基于无人机遥感的可见光与多光谱图像融合的陆地油田溢油检测算法研究提供了重要参考和改进方向。

1.3 论文研究内容

1.4 论文组织结构

第二章 相关理论和技术基础

2.1 多光谱成像原理

多光谱成像技术是指通过在多个离散光谱波段上对同一场景进行成像，从而获取目标在不同波段下的反射或辐射特性。相比传统的可见光 RGB 成像，多光谱成像能够提供更加丰富的光谱信息，有助于增强不同地物之间的可分性，在遥感监测、环境感知与目标识别等领域具有重要应用价值。

从光谱信息获取方式的角度出发，光谱成像系统可根据其对场景光谱信息的编码方式，大致分为扫描式成像和快照式成像两大类。扫描式光谱成像方法通常包括点扫描、线扫描（推扫式）以及光谱扫描等形式。这类方法通过在空间维度或光谱维度上逐步扫描目标场景，实现对高维光谱信息的获取。扫描式成像系统具有光谱分辨率高、成像精度较好的优点，在静态场景下能够获得质量较高的光谱数据。然而，由于其成像过程依赖机械扫描或时间序列采集，不可避免地存在成像速度慢、系统结构复杂、成本较高等问题，在动态场景或对实时性要求较高的应用中受到一定限制。

为满足动态场景下对光谱信息快速获取的需求，快照式光谱成像技术逐渐受到关注。快照式成像方法通过一次曝光即可获取多个光谱通道的数据，从而避免了扫描过程带来的时间延迟问题。典型的快照式光谱成像系统包括基于编码孔径或压缩感知理论的光谱成像方法，该类方法通过设计特定的空间或光谱编码结构，在单次曝光下获取混合光谱信息，并利用重建算法恢复高维光谱数据。尽管此类方法在理论上能够实现高光谱快照成像，但其对编码结构设计和重建算法依赖较强，系统实现复杂，设备成本较高，且在实际应用中生成的光谱图像质量和稳定性仍存在一定局限。

在上述背景下，基于多通道阵列传感器的多光谱成像方式逐渐成为工程应用中的一种重要替代方案。该类方法通常通过在传感器层面引入多个独立的光谱通道，实现对有限数量光谱波段的同步采集。按照成像结构的不同，多光谱成像系统可进一步分为推扫式成像和阵列式成像。推扫式多光谱成像系统沿着飞行或运动方向逐行获取多波段信息，适用于大范围遥感场景，但仍然存在一定的时间延迟和波段错位问题。相比之下，阵列式多光谱成像系统通过在空间上布置多个光

谱通道的成像单元，使不同波段能够在同一时刻对场景进行采集，从而在一定程度上提高了多光谱数据的时间一致性。

在实际工程实现中，一种常见的阵列式多光谱成像方案是采用多个独立的单波段相机，通过规则阵列排布的方式构成多光谱成像系统。该类系统中，每个相机对应一个特定的光谱波段，不同波段之间通过空间排布形成整体多光谱观测能力。这种基于独立单波段相机的阵列式结构具有系统灵活性高、波段可定制性强以及成本相对可控等优点，因而在无人机多光谱遥感等应用场景中得到广泛采用。然而，由于各光谱通道在空间位置和成像视角上存在差异，不同波段图像之间往往存在几何偏移和尺度差异，这对后续多光谱数据融合与目标检测提出了更高要求。

近年来，随着新型光学材料与微纳制造技术的发展，基于超表面结构的多光谱成像方法也逐渐成为研究热点。超表面成像通过在单一光学元件上实现对不同波段光的调制与分离，有望在紧凑结构下实现多光谱信息获取。尽管该类方法在集成度和系统体积方面具有潜在优势，但目前仍处于研究探索阶段，在工程成熟度和应用普及性方面尚有一定差距。

综上所述，不同多光谱成像方式在成像同步性、系统复杂度、光谱分辨率以及工程实现难度等方面各具特点。阵列式多光谱成像系统在保证多波段同步采集的同时，能够兼顾系统复杂度与实时性需求，因而在无人机平台和实时目标检测等应用场景中具有较高的实用价值。然而，其多通道成像结构也不可避免地引入了波段间的空间不一致性问题，这为后续多光谱数据配准与特征融合带来了挑战。上述成像特性的理解为后文多光谱数据处理与目标检测方法的设计提供了必要的理论基础。

2.2 深度学习相关理论

2.2.1 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）是一类针对图像等具有规则网格结构数据设计的深度学习模型，在计算机视觉领域得到了广泛应用。与传统全连接神经网络相比，卷积神经网络通过局部连接和权值共享机制，能够有效利用图像的空间结构特性，在降低模型参数规模的同时提升特征表达能力，

因此成为目标检测、图像识别等视觉任务中的基础网络结构。

卷积神经网络通常由卷积层、非线性激活层以及下采样层等基本模块构成，其整体结构如图 1 所示。卷积层通过卷积核在输入图像或特征图上进行滑动计算，用于提取局部空间特征；不同卷积核可响应图像中不同的结构模式，从而形成多通道特征表示。随着网络层数的加深，卷积神经网络能够逐步完成从边缘、纹理等低级特征到具有更强语义信息的高层特征的抽象表示，为复杂视觉任务提供有效的特征基础。




图 1 卷积神经网络结构图

在卷积操作之后，网络通常引入非线性激活函数以增强模型的表示能力。当前视觉任务中广泛采用 ReLU^[63]及其变体作为激活函数，以缓解梯度消失问题并加快模型收敛速度。同时，为了降低特征维度并扩大感受野，卷积神经网络中常结合下采样操作对特征图进行空间压缩。下采样有助于提升模型对局部扰动的鲁棒性，但也会在一定程度上造成空间细节信息的丢失，这在目标检测任务中可能对小尺度目标的定位精度产生不利影响。

随着网络深度的不断增加，深层卷积神经网络在特征表达能力方面取得了显著提升，但同时也暴露出网络退化问题，即在网络层数持续加深的情况下，模型训练误差不降反升，严重影响模型性能。以残差网络 (Residual Network, ResNet)^[64]为代表的结构通过引入跨层连接，使深层卷积神经网络的训练过程更加稳定，从而显著提升了模型的特征提取能力。

ResNet 的核心思想是在网络中引入跨层的快捷连接 (skip connection)，将输入特征直接与卷积变换后的输出相加，使网络的学习目标由原始映射函数 $H(x)$ 转变为残差函数 $F(x)$ ，其关系可表示为

$$H(x) = F(x) + x$$

其中， x 表示残差块的输入特征， $F(x)$ 表示由卷积层学习得到的残差映射。通过这种残差学习机制，信息和梯度能够在网络中跨层直接传播，从而有效

缓解深层网络训练过程中常见的梯度消失与梯度爆炸问题。




图 2 残差网络结构图

如图 2 所示，ResNet 通过将多个残差块进行级联构建深层网络结构，每个残差块通常由若干卷积层及一条恒等映射或线性变换的快捷连接路径组成，为后续视觉任务提供稳定的多层次特征表示。

2.2.2 注意力机制

注意力机制（Attention Mechanism）是一类用于刻画特征之间重要性差异与依赖关系的建模方法，其核心思想是根据上下文条件对输入特征进行自适应加权，从而突出关键信息并抑制冗余特征。注意力机制通过显式建模特征之间的相关性，使网络具备更强的特征选择能力和全局建模能力。

从统一的计算视角出发，注意力机制通常基于**查询（Query）、键（Key）和值（Value）**之间的映射关系进行形式化建模。给定输入特征矩阵

$X \in \mathbb{R}^{N \times d}$ 中 N 表示特征单元数量， d 表示特征维度，通过线性映射可得到：

$$Q = XW_Q, K = XW_K, V = XW_V$$

其中， $W_Q \in \mathbb{R}^{d \times d_k}$ 、 $W_K \in \mathbb{R}^{d \times d_k}$ 、 $W_V \in \mathbb{R}^{d \times d_v}$ 可学习参数矩阵。

基于上述定义，注意力计算的一般形式可表示为：

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

其中， $\frac{QK^T}{\sqrt{d_k}}$ 用于度量查询与各键之间的相似性， softmax 函数对相似度结果进行归一化处理以获得注意力权重分布，最终通过对值向量的加权求和，实现对输入特征的选择性聚合。

在此统一计算框架下，根据 Query、Key 和 Value 的来源不同，以及注意

力作用维度的差异,可进一步形成多种具体的注意力机制形式,本小节分别对自注意力机制、交叉注意力机制、空间注意力机制和通道注意力机制进行阐述。

2.2.2.1 自注意力机制 (Self-Attention)

自注意力机制 (Self-Attention) ^[25] 是注意力机制的一种典型形式,其特点在于查询 (Query)、键 (Key) 和值 (Value) 均由同一输入特征映射得到。与传统依赖局部感受野的卷积操作不同,自注意力机制允许每一个特征单元在建模过程中与所有特征单元建立联系,从而实现对全局上下文信息的联合建模。

$$Q = XW_Q, K = XW_K, V = XW_V$$

其计算形式可写为:

$$\text{SelfAttn}(X) = \text{softmax} \left(\frac{XW_Q (XW_K)^T}{\sqrt{d_k}} \right) XW_V$$

在该结构中,每一个特征单元在更新自身表示时,都会依据与其他特征单元的相似性分配注意力权重,从而将全局上下文信息融入当前特征表示之中。通过这种方式,自注意力机制能够显式建模长距离依赖关系,是 Transformer 架构中的核心计算单元。

在自注意力机制的基础上,多头自注意力机制 (Multi-Head Self-Attention) 进一步通过并行构建多个自注意力子空间,以增强模型对复杂特征关系的建模能力。对于第 i 个注意力头,其计算形式为:

$\text{head}_i = \text{Attention}(XW_Q^{(i)}, XW_K^{(i)}, XW_V^{(i)})$ 多个注意力头的输出在特征维度上进行拼接,并通过线性映射得到最终结果:

$\text{MultiHead}(X) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W_O$ 多头自注意力并未改变自注意力的基本计算范式,而是通过特征子空间的分解与融合,使模型能够从不同角度捕捉特征之间的多样化依赖关系,从而提升整体特征表达能力。

2.2.2.2 交叉注意力机制 (Cross-Attention)

交叉注意力机制 (Cross-Attention) 用于建模来自不同特征源或不同模态之间的关联关系。与自注意力不同,其查询向量与键和值向量来源于不同输入特征。设两个特征源分别为 X_1 和 X_2 , 则:

$$Q = X_1W_Q, K = X_2W_K, V = X_2W_V$$

交叉注意力的计算形式为:

$$\text{CrossAttn}(X_1, X_2) = \text{softmax} \left(\frac{X_1W_Q (X_2W_K)^T}{\sqrt{d_k}} \right) X_2W_V$$

该机制通过以 X_1 为查询条件, 对 X_2 中的特征信息进行有针对性的加权聚合, 从而显式建立不同特征源之间的对应关系。在多模态、多光谱以及编码器-解码器结构中, 交叉注意力为跨特征交互提供了重要的理论支撑。

2.2.2.3 空间注意力机制 (Spatial Attention)

空间注意力机制主要用于刻画特征图中不同空间位置的重要性差异。设输入特征图为

$F \in \mathbb{R}^{H \times W \times C}$ 间注意力权重图可表示为:

$$A_s = \sigma(f_s(F))$$

其中, $f_s(\cdot)$ 表示空间注意力生成函数, $\sigma(\cdot)$ 为 sigmoid 激活函数。

最终的空间加权特征表示为:

$$F' = A_s \odot F$$

其中, $\odot$ 表示逐元素相乘。空间注意力通过为不同空间位置分配权重, 引导模型关注具有判别意义的区域结构。

2.2.2.4 通道注意力机制 (Channel Attention)

光谱注意力或通道注意力机制用于刻画不同特征通道或光谱波段之间的重要性差异。设输入特征为

$F \in \mathbb{R}^{H \times W \times C}$ 先通过全局池化操作获得通道描述向量:

$$z = \text{Pool}(F)$$

在此基础上生成通道权重:

$$A_c = \sigma(g(z))$$

并对原特征进行逐通道加权:

$$F'_c = A_c \cdot F_c$$

该机制通过在通道或光谱维度上分配权重, 引导模型自适应地强调具有判别力的特征通道, 在多通道和多光谱特征建模中具有重要意义。

2.3 目标检测网络

2.3.1 DETR 网络

DETR (Detection Transformer) ^[27]是 Carion 等人在 2020 年提出的一种基于 Transformer 架构的端到端目标检测模型,其核心目标是从整体上简化传统目标检测流程。与依赖候选框生成、锚框设计以及非极大值抑制等后处理步骤的检测方法不同,DETR 将目标检测问题重新表述为一个集合预测 (set prediction) 问题,通过全局自注意力机制直接实现目标的定位与分类,从而在结构上实现真正的端到端建模。

DETR 的整体网络结构如图 xx 所示,主要由卷积神经网络主干、Transformer 编码器、Transformer 解码器以及预测头组成。首先,输入图像通过 CNN 主干网络提取二维特征图,该阶段主要负责对局部纹理和结构信息进行建模。为了保留空间位置信息,DETR 在特征图上引入位置编码,并将其与卷积特征相加后作为 Transformer 编码器的输入。编码器通过多层自注意力机制对特征序列进行全局建模,使网络能够在整个图像范围内建立不同位置特征之间的依赖关系。

在解码阶段,DETR 引入了一组可学习的目标查询向量 (Object Queries),每一个查询向量对应一个潜在目标实例。解码器通过查询向量与编码器输出特征之间的交叉注意力机制,从全局特征中逐步提取与目标相关的信息,并在多层解码过程中不断细化目标的语义和位置信息。最终,解码器输出的特征经过前馈网络,分别预测目标类别以及对应的边界框参数。

与原始 Transformer 在序列建模任务中的应用不同,DETR 针对图像数据的特点对编码器-解码器结构进行了适配。一方面,DETR 不再使用序列掩码机制,而是充分利用图像特征在空间上的并行性,实现多目标的同时预测;另一方面,通过将位置编码显式引入注意力计算过程,使模型能够区分不同空间位置的视觉特征,从而提高目标定位的准确性。该结构示意图如图 xx 所示。

DETR 的一大优势在于其查询式检测机制。由于预测结果与真实目标之间采用集合匹配策略进行一一对应,模型在训练和推理阶段均无需额外的候选框筛选或重复框抑制操作。这种设计不仅简化了检测流程,也增强了模型在理论上的一致性和可解释性。然而,由于解码器需要对固定数量的查询向量进行逐步更新,

原始 DETR 在训练收敛速度和推理效率方面存在一定不足，尤其在高分辨率图像或实时检测场景中表现受限。

尽管如此, DETR 提出的端到端检测思想和基于查询的预测范式为后续基于 Transformer 的目标检测模型奠定了重要基础。围绕其收敛速度、计算复杂度以及多尺度建模能力等问题，研究者相继提出了多种改进方法，使 DETR 系列模型在实际工程应用中的可行性不断提升。上述理论为本文后续采用和改进 Transformer 检测框架提供了必要的模型背景与技术基础。

2.3.2 RT-DETR

2.3.2.1 RT-DETR 网络结构与关键技术

针对原始 DETR 在收敛速度慢、计算开销大以及实时性不足等问题，研究者提出了 RT-DETR（Real-Time Detection Transformer）模型。该方法在保持端到端检测范式的基础上，对网络结构与特征建模方式进行了针对性优化，使 Transformer 架构能够更好地适配实时目标检测任务。

RT-DETR 的核心设计思想可以概括为三点：一是通过结构重构降低 Transformer 的计算复杂度，从而提升推理效率；二是引入多尺度特征建模机制，增强模型对不同尺度目标的感知能力；三是通过更合理的查询初始化策略，提高解码阶段的预测稳定性与定位精度。上述改进使 RT-DETR 在速度与精度之间取得了更优平衡。

RT-DETR 的整体网络结构如图 xx 所示，主要由主干网络、编码器和解码器三部分组成，各模块在功能上相互协同，共同完成目标检测任务。

2.3.2.2 主干网络（Backbone）

RT-DETR 的主干网络通常采用 ResNet 系列或 HGNetv2 等卷积神经网络结构，用于从输入图像中提取多层次特征表示。主干网络通过多层卷积与下采样操作，逐级降低特征图空间分辨率的同时提升语义表达能力，从而构建具有不同尺度和语义层级的特征金字塔。

在具体实现中，卷积模块通常由卷积运算、批量归一化和非线性激活函数组成，用于提取局部结构与纹理信息；池化操作用于减少特征图尺寸，降低后续计算开销。残差结构的引入有效缓解了深层网络训练中的梯度衰减问题，使得网络能够在保持较深层次的同时维持稳定训练。主干网络在不同阶段输出的特征图通

常对应不同的下采样比例，其中中高层特征被送入后续编码器进行多尺度建模，为检测任务提供丰富的特征基础。

2.3.2.3 编码器 (Encoder)

编码器的主要作用是对主干网络输出的多尺度特征进行进一步建模与融合，以增强特征的全局语义表达能力。与标准 Transformer 编码器不同，RT-DETR 在编码阶段引入了尺度内特征交互与跨尺度特征融合相结合的设计，以适应目标检测中多尺度目标共存的特点。

在同一尺度内，编码器通过基于注意力机制的特征交互模块对特征进行重构，使网络能够在空间维度上捕捉不同位置之间的依赖关系。该过程通过将二维特征映射转换为序列形式，引入自注意力机制完成全局信息建模，随后再恢复为二维结构，以便保留空间结构信息。该设计在增强深层特征语义表达的同时，避免了过高的计算成本。

在跨尺度建模方面，编码器通过卷积操作、上采样以及特征拼接等方式对来自不同层级的特征图进行融合。低层特征通常具有较高的空间分辨率但语义信息有限，而高层特征则包含更丰富的语义但空间细节不足。通过跨尺度融合机制，不同层级的特征得以在统一空间尺度下进行整合，使模型同时兼顾目标的精细边界信息与高层语义表达能力，从而提升对小目标和复杂场景的检测性能。

2.3.2.4 解码器 (Decoder)

解码器负责将编码器输出的特征映射转化为最终的目标类别与边界框预测结果。RT-DETR 在解码阶段延续了基于查询的预测范式，但对查询向量的生成方式进行了优化。与原始 DETR 随机初始化查询向量不同，RT-DETR 引入了基于预测质量的查询选择策略，使解码器能够从更具代表性的特征中进行目标建模。

具体而言，模型在编码阶段对候选特征进行评估，并根据预测框与真实目标之间的重叠程度筛选高质量特征作为解码器的初始查询。这种方式能够为解码器提供更接近真实目标位置的先验信息，从而减少无效查询带来的干扰。解码器在多层迭代过程中不断更新查询特征，逐步细化目标的类别判断和边界框回归结果，实现更加稳定和精确的检测输出。

2.4 多光谱目标检测网络

MRT-DETR: a robust visible–infrared object detector with adaptive cross-modal feature fusion

在复杂环境条件下，单一可见光模态目标检测网络容易受到光照变化、遮挡以及恶劣天气等因素的影响，其检测性能在实际应用中表现出明显的不稳定性。多光谱成像系统通过在不同光谱波段对同一场景进行观测，为目标检测网络提供了更加丰富且互补的信息来源。其中，可见光图像具有分辨率高、纹理和颜色信息丰富等优势，而多光谱图像能够在可见光之外的其他波段获取目标的光谱响应信息，不同材料和目标在各波段下表现出显著差异，从而在复杂环境中增强目标与背景的可分性。由于各光谱波段在成像机理和信息分布上的差异，多光谱数据在感知维度上具有显著互补性，为构建鲁棒的全天候目标检测网络提供了重要基础。 **引用文献**

多光谱目标检测网络的核心问题在于如何在统一的网络框架内组织和融合来自不同光谱波段的特征信息，使网络结构既能够充分利用各波段的判别优势，又能够抑制冗余或冲突特征。围绕多光谱信息在检测网络中的组织方式与融合位置，现有多光谱目标检测网络通常根据融合机制的不同进行分类，不同融合机制对应着不同的网络结构形式和性能特征。

2.4.1 基于像素级融合的多光谱目标检测网络结构

基于输入级融合的多光谱目标检测网络在网络输入端对不同光谱图像进行像素级对齐，并通过通道拼接或叠加的方式将多模态信息统一编码为多通道输入，随后送入单一目标检测网络完成特征提取与目标预测^[65,66]。在网络结构设计上，该类方法通常采用单流检测框架，能够在不改变主干网络结构的前提下，实现对多光谱输入的直接支持。




图 3 像素级融合

该类网络结构整体紧凑，实现简单，工程改造成本较低，且推理效率较高，适合对实时性要求较强的应用场景。然而，由于不同光谱在成像机理和信息表达方式上的差异，简单的通道叠加难以在网络结构中保持各模态特征的独立建模能力。同时，该结构对多光谱图像的空间配准精度高度敏感，一旦存在对齐误差，融合后的输入特征中容易引入噪声干扰，从而影响网络的检测性能。此外，输入级融合在网络早期即混合多模态信息，限制了网络结构对模态差异进行针对性建模的能力，其整体性能提升空间相对有限。

2.4.2 基于特征级融合的多光谱目标检测网络结构

基于特征级融合的多光谱目标检测网络是当前应用最为广泛的一类网络结构形式。其基本思想是在网络结构中为不同光谱数据分别构建特征提取分支，并在中间特征层或多尺度语义层引入跨模态交互模块，实现特征融合与互补建模^[67,68]。在具体实现上，该类网络通常采用双流或多流结构，各模态特征在保持相对独立的同时，通过特征拼接、加权融合或注意力机制等方式进行交互。

相比基于输入级融合的单流网络结构，特征级融合网络能够在特征空间中显式建模不同光谱之间的语义关联，在保持各模态判别信息完整性的同时，实现更加细粒度的信息互补，从而在检测精度与计算复杂度之间取得较优平衡。因此，该类网络结构已成为多光谱目标检测领域的主流设计范式。部分网络通过在融合模块中引入动态权重机制，对不同模态特征的贡献进行自适应调节，以提升网络对复杂场景的适应能力^[69]。




图 4 特征级融合

然而，现有特征级融合网络结构仍面临若干关键挑战。一方面，部分网络仅在通道或全局层面生成统一权重，对整幅图像施加一致调制，难以刻画由于光照变化或目标属性差异引起的空间异质性，容易抑制局部关键区域的有效特征表达。另一方面，多光谱特征在网络结构中的空间对齐问题仍然较为突出。由于可见光与多光谱图像通常由不同传感器采集，在视场范围和成像角度上不可避免地产生偏差^[70]。当对齐操作在低分辨率深层特征上进行时，微小的空间误差在后续上采样过程中会被逐级放大，产生累计定位偏差，从而影响检测结果的精确性。

2.4.3 基于决策级融合的多光谱目标检测网络结构

基于决策级融合的多光谱目标检测网络在网络输出阶段对不同模态的检测结果进行整合。该类网络通常为每种光谱数据分别构建独立的检测分支，各分支完成目标定位与分类后，通过置信度加权、投票机制或非极大值抑制等方式对检测结果进行融合^[71,72]。在网络结构层面，该类方法具有较强的模块独立性，便于系统扩展与工程集成。

基于决策级融合的网络结构对多光谱图像的配准精度要求相对较低，能够在一定程度上缓解模态间空间偏移带来的影响。然而，由于模态间的交互仅发生在预测结果层，该类网络难以在特征空间中建模不同光谱之间的深层语义关联，无法充分挖掘多光谱特征的互补优势，在复杂环境下的整体检测性能提升通常较为有限。




图 5 决策级融合

综合来看，不同融合机制对应的多光谱目标检测网络结构在性能与适用场景方面各具特点。基于输入级融合的单流网络结构实现简单、推理效率高，但对配准误差敏感且特征利用能力有限；基于决策级融合的多分支网络结构具有较强的模块独立性和系统鲁棒性，但缺乏深层跨模态特征交互；基于特征级融合的多流网络结构在保持模态独立建模能力的同时，实现了有效的信息互补，在检测精度与计算效率之间取得了较优平衡。

因此，从网络设计与实际应用的角度出发，基于特征级融合的多光谱目标检测网络为构建高效、稳健的多模态感知系统提供了更加灵活且具有工程可行性的技术路径，也为后续多光谱融合检测网络的设计奠定了理论基础。

2.5 目标检测评估指标

在目标检测任务中，评估指标用于定量衡量模型在目标定位与分类方面的综合性能，是不同算法之间进行公平对比的重要依据。针对检测精度与实时性等核心需求，本文主要采用准确率（Precision）、召回率（Recall）、平均精度（Average Precision, AP）、均值平均精度（Mean Average Precision, mAP）以及每秒检测帧数（Frames Per Second, FPS）等指标对模型性能进行评估。

1. 准确率（Precision）

准确率用于衡量模型预测为目标的检测结果中，实际为真实目标的比例，反映了模型对误检情况的抑制能力。准确率越高，表示模型输出的检测结果中错误预测的比例越低。其计算公式如下：

$$P = \frac{TP}{TP + FP}$$

其中，TP（True Positive）表示被模型正确检测并匹配到真实目标的预测框数量，FP（False Positive）表示模型错误预测的目标框数量。

2. 召回率（Recall）

召回率描述了所有真实目标中被模型成功检测出的比例，主要反映模型对漏检问题的敏感程度。在对目标遗漏较为敏感的应用场景中，召回率是一个尤为重要的评价指标。其计算公式为：

$$R = \frac{TP}{TP + FN}$$

其中，FN（False Negative）表示未被模型检测出的真实目标数量。

3. 平均精度（Average Precision, AP）

平均精度（AP）是目标检测中常用的综合性能评价指标，用于衡量某一类别在不同召回率水平下的整体检测表现。AP 定义为准确率-召回率（Precision-Recall, PR）曲线下的面积，其数值反映了模型在不同阈值条件下维持高精度预测的能力。AP 的数学定义如下：

$$AP = \int_0^1 P(R) dR$$

AP 值越大，表示模型在该类别上的检测性能越优，能够在较宽的召回率范围内保持较高的预测准确性。

4. 均值平均精度（Mean Average Precision, mAP）

均值平均精度（mAP）是在多类别目标检测任务中对模型整体性能的综合评价指标，定义为所有类别 AP 的算术平均值，其计算公式为：

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i$$

其中，N 表示目标类别总数， AP_i 表示第 i 类目标对应的平均精度。

在实际评估中，mAP 通常结合不同的交并比（Intersection over Union, IoU）阈值进行计算。例如，mAP@0.5 表示在 IoU 不小于 0.5 的条件下计算各类别 AP 并取平均；而 mAP@0.5:0.95 则表示在 IoU 从 0.5 到 0.95 之间以 0.05 为步长分别计算 AP，最终对所有 IoU 阈值和类别进行平均。相比 mAP@0.5，mAP@0.5:0.95 评价标准更加严格，能够全面反映模型在不同定位精度要求下的检测性能。

2.6 本章小节

第三章 油田溢油数据集构建与预处理

3.1 引言

本章围绕多光谱溢油检测任务的数据基础，系统介绍数据采集区域、无人机与多光谱成像系统配置，以及原始数据的预处理与配准方法。通过构建真实场景下的多光谱溢油数据集，并对多通道图像进行精确对齐处理，为后续检测模型的训练与性能评估提供可靠的数据支撑。

3.2 研究区域

如图 6 所示，本研究的数据采集区域位于中国黑龙江省大庆市，地理范围约为东经 $123^{\circ}45'$ – $125^{\circ}47'$ 、北纬 $45^{\circ}23'$ – $47^{\circ}29'$ 。该区域是我国最具代表性的陆上石油开发基地之一，油气资源储量丰富，石油开采与输送活动长期集中分布，具有典型的陆地油田生产环境特征。




图 6 黑龙江省大庆市大庆油田片区

同时，大庆油田周边分布有居民区、道路交通设施及多种工业基础设施，油

气开采、运输与人类活动高度交织，使得该区域在实际生产过程中存在一定的原油泄漏与污染风险。一旦发生溢油事件，不仅会对地表生态环境造成破坏，还可能对周边居民生活与工业安全产生不利影响。该区域地形相对平坦，地物类型具有代表性，便于无人机平台开展稳定飞行与成像作业。

3.3 数据采集设备与多光谱成像系统

3.3.1 成像设备与无人机平台配置

如图 7 所示本研究采用大疆 M300 RTK 工业级无人机作为数据采集平台搭载深圳市中达瑞和科技有限公司的 MAX-G800 光谱相机。该无人机具备较强的载荷能力、稳定的飞行性能以及高精度定位能力，能够在复杂户外环境下保持良好的飞行姿态，为多光谱成像任务提供稳定可靠的载体支持。




图 7 大疆 M300 RTK 搭载 MAX-G800

多光谱成像设备 MAX-G800 光谱相机的主要参数如表 1 所示，该相机支持可见光 RGB 通道与 7 个多光谱窄带通道的同步成像，中心波长范围 450nm-850nm，覆盖了从可见光至近红外的典型光谱范围。整机重量约 766 g，功耗低于 10 W，适合无人机平台在复杂油田环境下进行长时间、多批次的数据采集。

表 1 MAX-G800 多光谱相机主要参数

参数类别	数值
产品型号	MAX-G800
多光谱成像	7 + RGB
多光谱波段	450nm、550nm、650nm、720nm、750nm、800nm、850nm
图像传感器	1/2.9 英寸 CMOS，全局快门， 155 万像素
图像分辨率	1440 * 1080
光学镜头	焦距 $f=5.35\text{mm}$ ，光圈 F/2.0
视场角	HFOV: 49.8°，VFOV: 38.4°
采集帧频	20 帧/秒（实时）
飞行平台	可匹配飞行平台（旋翼无人机、固定翼无人机、无人飞艇等）
功耗	<10W

3.3.2 多光谱成像系统结构与成像特点

MAX-G800 多光谱相机采用 3×3 多摄像头阵列式排布结构，阵列中各子摄像头分别负责不同光谱波段的图像采集。如图 8 所示，通过阵列式结构可实现多通道的同步成像，从而在无人机飞行等运动场景下同时获取 RGB 及多光谱波段图像，有效避免因时间间隔过大而引入的显著运动模糊与光照变化影响。

相较于采用滤光轮或时间复用方式的多光谱成像系统，阵列式多摄像头结构能够在保持较高空间分辨率的同时覆盖多个光谱波段，为地表目标提供更为丰富的光谱响应信息，具有较强的工程实用性，已在工业检测与环境监测等应用场景中得到广泛应用，尤其适合集成于无人机平台开展快速巡检作业。

然而，由于阵列中各摄像头在物理结构上存在不可避免的空间间隔，同时不同通道在成像时刻及成像路径上存在细微差异，不同波段图像之间往往会产生系统性的几何偏移。这类偏移通常表现为通道间的平移、旋转以及微小尺度差异，在高分辨率成像条件下尤为明显。

若不对上述几何偏移进行校正，多光谱通道在空间上将难以实现精确对齐，导致不同波段特征无法准确对应同一地表目标区域，从而削弱多光谱特征融合的有效性，并对后续目标检测与识别结果产生不利影响。因此，在数据预处理阶段有必要对多光谱图像进行精确配准，以消除通道间的空间偏移，为高质量多光谱数据集构建及后续算法研究奠定可靠基础。




图 8 MAX-G800 波段成像概览

3.4 数据采集设置

在油田场景的数据采集过程中，为在保证空间分辨率的同时兼顾单架次覆盖效率，MAX-G800 多光谱相机的无人机飞行高度主要控制在约 70 m。根据相机标定参数，其水平视场角 (Horizontal Field of View, HFOV) 和垂直视场角 (Vertical Field of View, VFOV) 分别为 $\theta_x = 49.8^\circ$, $\theta_y = 38.4^\circ$ ，在假设相机正下视成像且地表近似平坦的条件下，可依据成像几何关系计算得到在飞行高度为 70 m 时，单幅图像在地面上的水平覆盖宽度 W 与垂直覆盖高度 L ，其计算过程如公式(3-1)所示：

$$\begin{aligned} W &= 2H \tan\left(\frac{\theta_x}{2}\right), \\ L &= 2H \tan\left(\frac{\theta_y}{2}\right) \end{aligned} \quad (3-1)$$

在此基础上，考虑传感器分辨率为 1440×1080 像素，地面空间分辨率 (Ground Sampling Distance, GSD) 可表示为地面覆盖范围与对应像素数之比，其计算公式如公式 (5-2) 所示：

$$\begin{aligned} \text{GSD}_x &= \frac{W}{N_x}, \\ \text{GSD}_y &= \frac{L}{N_y} \end{aligned} \quad (3-2)$$

根据上述计算结果，在约 70 m 飞行高度条件下，单幅图像对应的地面覆盖范围约为 65 m × 49 m，地面空间分辨率可达到约 4.52 cm/pixel。该空间分辨率能够有效表征厘米级地表溢油特征，包括油膜边缘形态、局部渗油痕迹以及弱对比度扩散区域，为后续溢油目标检测与识别提供高精度的原始数据基础。




图 9 传感器采集原理

3.5 原始数据预处理与标注

基于上一节对多光谱成像系统几何特性的分析，为缓解多光谱图像在成像视角、传感器安装位置及成像机理差异等因素影响下产生的空间不对齐问题，本文在数据预处理阶段采用了一种两阶段配准策略，依次完成粗配准与精细配准，以实现多光谱图像之间的高精度空间对齐。

在第一阶段，采用相位相关（Phase Correlation）方法对不同波段图像进行粗配准。该方法基于傅里叶变换理论，通过分析图像在频域中的相位差信息，快速估计图像之间的全局平移偏差。相位相关方法具有计算效率高、对噪声具有一定鲁棒性且不依赖显式特征点提取的优点，能够在较低计算成本下有效消除多光

谱通道间的整体位移误差，适合作为多光谱图像初始对齐的手段。通过该阶段处理，各波段图像之间的相对位移被控制在较小范围内，为后续精细配准提供稳定可靠的初始位姿。

在完成粗配准后，为进一步消除由视角差异、镜头畸变及安装误差等因素引入的残余几何偏差，本文引入基于深度学习的特征匹配方法进行精细配准。具体而言，采用 MatchAnything 模型中的 Dense Matcher 模块，并使用其 ROMA（Robust Optical flow Matching Anything）版本的预训练权重，对多光谱图像对进行稠密特征匹配。该方法通过学习到的深层特征表示，在不同光谱模态之间建立稳定且鲁棒的像素级对应关系，相较于传统手工特征方法，在跨模态场景下具有更强的匹配一致性与泛化能力。

在精细配准过程中，首先以可见光图像作为参考图像，与其他光谱通道分别进行稠密匹配，获得高质量的像素级对应关系；随后根据匹配结果估计仿射或相似变换模型，并对待配准图像进行插值重采样，从而实现精确的空间对齐。该基于深度特征的配准方式能够有效处理旋转、非均匀偏移及局部尺度变化问题，显著提升多光谱图像之间的对齐精度。

经过上述两阶段配准处理后，各波段多光谱图像在空间上保持高度一致，不同地表目标在多光谱图像中的位置对应关系准确。实验结果表明，该方法在保证计算效率的同时，实现了接近亚像素级的对齐精度，为后续多光谱特征提取与目标检测模型训练提供了高质量的数据输入。




图 10 配准示例

除空间配准外，数据预处理流程还包括必要的图像去噪、裁剪以及光照归一化等操作，以降低成像噪声及光照变化对多光谱分析的影响，进一步增强数据在空间和光谱维度上的一致性与稳定性。

在完成配准与预处理后，本文对多光谱数据集进行了人工标注与统计分析。原始数据集中共筛选出 194 张不同时间不同地点拍摄的多光谱原始图像，每张图像均包含 RGB 通道及 7 个多光谱窄带通道。为满足深度学习模型输入尺寸要求并扩大样本规模，本文将原始图像裁切为 640×640 的图像块，最终构建得到 634 张多光谱图像样本。

在目标类别设置方面，数据集共标注三类具有代表性的地表目标，分别为原油溢出区域、工业机械设备、建筑物。上述类别在实际油田与工业场景中分布广泛，且在多光谱影像中易对溢油目标检测产生干扰，具有较高的研究与应用价值。

表 2 溢油数据集标签类别分布

Annoations	Number	Ratio(%)
Oil	1034	70.0
Machine	245	16.6
Building	197	13.4
All	1476	100

在数据集划分上，按照训练集、验证集与测试集 7:2:1 的比例对样本进行划分，最终得到 446 张训练样本、124 张测试样本以及 64 张验证样本。尽管整体数据规模相对有限，但所有样本均来源于真实油田与工业环境，具备较高的真实性与场景针对性，能够有效用于验证所提出多光谱溢油检测模型在小样本条件下的检测性能与泛化能力。

3.6 数据分析

如图 9 所示，右侧给出了所采集区域内典型地表样本的多光谱反射曲线。为分析不同地表类型在多光谱空间中的响应特性，本文在图像中选取了多个代表性 ROI 区域，并分别提取其在各波段上的平均光谱值进行对比分析。

从溢油相关区域的光谱曲线可以看出，ROI_oil_water_mixture_1 与 ROI_oil_water_mixture_2 虽然位于同一溢油点的不同空间位置，但在各多光谱波段上呈现出高度一致的变化趋势，整体光谱形态具有较高相似性。这表明在一定空间范围内，溢油与水体混合区域的光谱响应具有较好的稳定性，其光谱特征主要受溢油成分及覆盖比例的共同影响，而受局部空间位置变化的影响相对较小。

对于 ROI_sewage 区域，其光谱曲线在整体趋势上与溢油混合区域保持一定相似性，尤其在可见光及近红外部分波段中表现出接近的反射响应。然而，相较于典型溢油混合区域，该区域在部分波段上呈现出幅值降低或局部形态差异，推测其溢油成分占比较低，或仅存在轻微的油污混合现象。这一结果说明在实际油田环境中，不同水体污染程度对应的光谱特征存在连续变化，而非严格的二值区分。相比之下，ROI_puddle 所对应的未受溢油污染区域在多光谱曲线上与溢油相关区域呈现出明显差异。其光谱曲线整体形态与溢油混合区域存在显著偏离，尤其在近红外波段上反射响应差异更为明显，表明该区域水体成分及表面物理特性与溢油污染区域存在本质差异。

综合上述分析可以看出，不同类型水体在多光谱空间中具有可区分的光谱响应特征，且溢油混合区域在一定程度上表现出较为稳定的光谱相似性。这为基于多光谱信息的溢油识别与检测提供了重要依据，同时也表明仅依赖单一波段或简单阈值方法难以应对污染程度连续变化的复杂场景，有必要引入多波段联合建模或特征融合策略，以提升溢油检测的鲁棒性与泛化能力。

3.7 本章小节

第四章 基于感受野增强和跨尺度融合的目标检测算法

4.1 引言

XXX

4.2 算法设计

X

4.3 实验设计

4.4 实验结果与分析

Materials	Spacegroups	T_{mag} (K)	θ_{CW} (K)	Magneticgroundstate	References
γ -Li ₂ IrO ₃	Cccm	39.5	40	Spiral	[42]
α -RuCl ₃	$C2/m \rightarrow R\bar{3}$	7	39.6 (θ_{ab}) -216.4 (θ_{c})	Zigzag	[193]
Cu ₃ LiIr ₂ O ₆	C2/c	15	-145	Antiferromagnetic	[202]
Ag ₃ LiIr ₂ O ₆	$R\bar{3}m$	-	-142	SuspectedQSL	[207]
H ₃ LiIr ₂ O ₆	C2/m	-	-105	SuspectedQSL	[48]

4.5 本章小节

第五章 可见光与多光谱融合的端到端目标检测

5.1 引言

在前述章节中，围绕无人机平台下的多光谱溢油检测任务，对多光谱成像原理、数据采集流程以及数据集构建方法进行了系统分析。通过多源传感器协同采集可见光与多光谱图像，为复杂环境下溢油目标的稳定检测提供了更加丰富的信息基础。然而，在实际数据集构建与预处理过程中，不同模态影像在成像机制和采集方式上的差异，也不可避免地引入了一系列对检测模型性能具有重要影响的问题。

首先，可见光图像与多光谱图像通常由不同成像传感器获取，二者在视角、焦距、成像时间以及光学结构等方面均存在差异。即使经过几何校正与图像配准处理，仍难以在所有区域实现严格的一一对应关系，局部区域普遍存在亚像素级甚至像素级的残余偏移。其次，在多光谱图像内部，由于多波段成像往往采用分时扫描、滤光片切换或多通道拼接等方式完成，不同波段之间同样可能存在轻微的空间错位和形变。这种模态间与模态内的非严格对齐问题，在复杂背景、低纹理区域或目标尺度较小时尤为明显。

上述问题使得多光谱目标检测任务不再仅仅是特征互补的问题，而同时包含了跨模态空间一致性建模的挑战。若在检测模型中简单采用特征拼接或静态加权等融合方式，容易将空间不一致的特征强行叠加，进而引入噪声干扰，削弱多光谱信息在目标定位与边界回归中的实际贡献。因此，如何在端到端检测框架中同时兼顾跨模态特征交互与空间对齐鲁棒性，成为多光谱目标检测模型设计中的关键问题。

近年来，基于 Transformer 的端到端目标检测方法在全局特征建模和结构简洁性方面展现出明显优势。以 RT-DETR 为代表的检测框架，通过查询驱动的预测机制和全局注意力建模，实现了无需锚框和后处理的目标检测流程，在实时性与检测精度之间取得了较好的平衡。然而，原始 RT-DETR 主要针对单一可见光模态设计，其特征建模过程默认输入特征在空间上高度一致，难以直接适应多光谱数据中普遍存在的跨模态和跨波段对齐误差。

基于上述数据特性与模型局限性，本文以 RT-DETRv4 为基础，对其网络结构进行针对性的多模态扩展，引入适用于可见光与多光谱融合的端到端目标检测

框架。一方面，通过在 Transformer 架构中引入跨模态特征融合机制，使网络能够在全局语义空间中显式建模可见光与多光谱特征之间的关联关系，充分挖掘不同模态在纹理、结构与光谱信息上的互补优势；另一方面，针对数据集中客观存在的模态间与模态内空间不一致问题，引入具备可变形建模能力的特征对齐机制，使模型在存在局部偏移和轻微形变的情况下，仍能实现稳定有效的特征匹配与融合。

在此基础上，本章重点研究两类核心结构模块：**基于 Transformer 的跨模态特征融合模块（Cross-modal Fusion Transformer, CFT）**，用于实现可见光与多光谱特征的深层交互与联合表示；以及面向多模态空间偏移问题的**可变性对齐模块（Elastic Deformable Alignment, CRGGGA）**，用于提升模型对模态间空间错位的自适应能力。上述模块在设计上与 RT-DETR 原有端到端检测流程保持一致，使模型在增强多模态建模能力的同时，仍具备良好的训练稳定性与工程部署可行性。

本章后续内容将围绕所提出的多光谱融合端到端检测模型展开，依次介绍整体网络结构设计、跨模态融合与对齐模块的实现思路，并通过实验验证所提出方法在多光谱溢油检测数据集上的有效性与鲁棒性。

5.2 算法设计

骨干网络架构




图 11 双流骨干网络

5.2.1 规范参考引导的分组对齐方法(Canonical Reference Guided Groupwise Alignment)

针对多光谱成像系统中不同波段通道由于成像响应差异、光谱敏感度不一致以及传感器内部光路误差等因素所导致的通道级空间错位问题，本文在骨干网络的浅层特征阶段引入一种规范参考引导的分组对齐模块（Canonical Reference Guided Groupwise Alignment, CRGGA）。如图 12 所示，该模块以多光谱内部通道特征作为对齐对象，通过构建统一的规范参考特征，通过学习采样偏移场引导不同光谱通道在空间维度上进行自适应重排，从而增强各通道在局部结构层面的几何一致性，为后续跨模态特征融合与语义建模提供稳定、可靠的对齐基础。

将 CRGGA 模块布置于网络的浅层特征阶段主要基于以下考虑：一方面，浅层特征保留了丰富的空间细节信息，如边缘、轮廓及局部结构模式，这些信息对于准确建模不同光谱通道之间的几何错位具有重要意义；另一方面，浅层特征具有更高的空间分辨率，有利于对细微但具有实际影响的空间偏移进行精细化建模。通过在特征提取早期完成多光谱通道间的空间对齐，可有效避免对齐误差在深层网络中逐级累积，从而防止语义抽象过程掩盖潜在的几何不一致性，为后续特征融合提供更加一致的输入表示。

。




图 12 CRGGA 模块结构图

具体而言，CRGGA 模块的输入为主干网络第一阶段输出的多光谱特征图 $\mathbf{F}_{ms} \in \mathbb{R}^{B \times C \times H \times W}$ ，其中 B 、 C 、 H 、 W 分别表示批大小、通道数以及特征图的空间尺寸。不同于跨模态对齐场景中对可见光与红外特征进行区分建模，CRGGA 模块不显式区分模态来源，而是将多光谱各通道视为同一模态内部的不同观测子空间。该设计有助于在保持通道语义一致性的前提下，专注建模通道间由成像机制差异引入的空间响应不一致问题。

在多光谱特征中，不同波段由于成像机理、光谱响应范围及噪声特性的差异，其同一空间位置上的特征响应往往存在明显不一致。如果直接选取某一固定波段特征作为对齐参考，容易引入波段偏置，使对齐过程过度依赖单一通道的局部特性，从而降低整体稳定性。本文提出一种空间加权规范参考构建方法 (Spatial Weighted Canonical Reference, SWCR)，通过在每个空间位置上自适应融合多光谱通道信息，生成更加稳健的参考特征，用于引导后续的分组空间对齐过程。具体而言，对于 ms_stem 阶段的输出 $\mathbf{X} \in \mathbb{R}^{B \times N \times C \times H \times W}$ ，其中 N 表示光谱波段数量。首先，通过维度重排与 1×1 卷积操作对多光谱特征进行线性映射，得到每个波段在不同空间位置上的响应表示，如公式(5-1)所示：

$$\bar{\mathbf{s}} = \text{Conv}_{1 \times 1}(\bar{\mathbf{X}}) \in \mathbb{R}^{(BN) \times 1 \times H \times W} \quad (5-1)$$

该过程不引入额外的空间上下文信息，而是在像素级别上建模不同光谱通道的相对响应强度，为后续的权重归一化提供基础。在获得初始响应特征后，本文在光谱波段维度上引入 Softmax 归一化操作，对不同波段的响应进行标准化处理，如公式 (5-2)所示：

$$\mathbf{w} = \text{softmax}_n(\mathbf{s}) \in \mathbb{R}^{B \times N \times H \times W} \quad (5-2)$$

通过该归一化过程，模型能够在每个空间位置上自适应分配不同光谱通道的贡献比例，并确保各波段权重之和为 1，从而避免某一波段在全局范围内占据主导地位。随后，将归一化后的波段权重在通道维度上进行广播，并与原始多光谱

特征逐元素相乘，得到加权后的多光谱特征表示，如公式(5-3)所示：

$$\tilde{X} = X \odot w \in \mathbb{R}^{B \times N \times C \times H \times W} \quad (5-3)$$

该加权操作在空间位置与光谱波段两个维度上同时发挥作用，使得不同波段在不同空间区域能够根据其局部响应特性参与参考特征的构建。在此基础上，对加权后的多光谱特征在波段维度上进行聚合，得到最终的规范参考特征图，如公式(5-4)所示。

$$\mathbf{R} = \tilde{X}_n = \sum_{n=1}^N \mathbf{w}_n \odot \mathbf{X}_n = \text{sum}_n(\tilde{X}) \in \mathbb{R}^{B \times C \times H \times W} \quad (5-4)$$

所生成的规范参考特征在每个空间位置上综合了多光谱通道的局部响应信息，相较于单一波段特征，能够更加稳定地反映真实场景中的结构特征，并作为后续分组空间对齐与偏移预测的统一参考基准为充分利用规范参考特征与原始多光谱特征之间的互补信息，本文将二者在通道维度上进行拼接，形成联合特征表示，如公式(5-5)所示：

$$\mathbf{F}_{cat} = \text{Concat}(\mathbf{F}_{ms}) \in \mathbb{R}^{B \times 2C \times H \times W} \quad (5-5)$$

该联合特征同时包含稳定的结构参考信息与原始通道间的差异信息，有助于后续网络在预测空间偏移时更准确地刻画通道间的几何错位关系。

拼接后的特征送入由 3×3 卷积、GroupNorm 以及 ReLU 激活函数组成的初始卷积单元，在完成通道间初步信息交互的同时压缩冗余特征，因为在 MS Stem 中采用了 band 维并入 batch 的共享卷积来避免对齐前跨波段融合，为了避免 BatchNorm 混合不同波段/样本的统计量，从而引入隐式跨波段耦合并造成分布偏移；因此使用不依赖 batch 统计且对小 batch 更稳定的 GroupNorm 来替代 BN：

$$F^{conv1} = \text{ReLU}(\text{GN}(\text{Conv}_{3 \times 3}(F^{cat}))) \in \mathbb{R}^{B \times C \times H \times W} \quad (5-6)$$

在此基础上，引入一个轻量级特征增强子网络，由两个标准残差块与一个瓶颈结构块串联构成，用于进一步强化对多光谱局部结构与跨通道关联关系的建模能力：

$$\mathbf{F}_{conv2} = \text{Residual}(\text{Bottleneck}(\text{Residual}(\mathbf{F}_{conv1}))) \in \mathbb{R}^{B \times C \times H \times W} \quad (5-7)$$

块末端采用双分支预测结构，分别用于空间偏移建模与方向权重调制。其中，偏移预测分支通过 3×3 卷积生成每个空间位置对应的二维采样偏移量，并结合双曲正切函数与可学习尺度参数对其幅值进行约束：

$$\text{Offset} = \sigma_1 \cdot \tan h(\text{Conv}_{3 \times 3}^{\text{offset}}(F^{conv2})) \in \mathbb{R}^{B \times 2K \times H \times W} \quad (5-8)$$

其中 K 表示采样点数量，本文设置为 $K=9$ ， σ_1 为可学习缩放系数，输出包含每个采样点在水平方向与垂直方向上的偏移量 $(\Delta x_k | \Delta y_k)$ 。

为刻画不同采样方向在空间对齐过程中的相对重要性，CRGGA 模块引入方向注意力分支，用于为各个采样方向分配自适应权重。具体而言，该分支通过卷积操作对中间特征进行建模，并采用 Softmax 归一化生成方向感知注意力图：

$$Attn = \sigma_2 \cdot \text{Softmax}(\text{Conv}_{3 \times 3}^{attn}(F^{conv2})) \in \mathbb{R}^{B \times K \times H \times W} \quad (5-9)$$

其中 K 表示采样方向数量， σ_2 为可学习的尺度参数，用于调节注意力分布的整体幅值。在此基础上，以特征图中每个位置 p_0 作为参考采样点，CRGGA 模块预测对应的空间偏移量 $(\Delta x_k, \Delta y_k)$ ，并据此计算第 k 个采样方向的实际采样位置：

$$p_k = p_0 + \Delta p_k = p_0 + (\Delta x_k, \Delta y_k), \quad k = 1, \dots, K \quad (5-10)$$

该偏移建模方式使得网络能够根据局部特征结构，自适应调整不同光谱通道的采样位置，从而补偿由成像差异引起的空间错位。随后，在方向注意力权重的调制下，从多光谱特征图中对上述采样位置进行双线性插值采样，并对不同方向的采样结果进行加权融合，得到对齐后的多光谱特征表示：

$$F_{align}^{ms}(p_0) = \sum_{k=1}^K A_k(p_0) \cdot X^{ms}(p_k) \quad (5-11)$$

其中 $A_k(p_0)$ 表示位置 p_0 处第 k 个采样方向的注意力权重， $F_{ms}(p_k)$ 为对应位置的双线性插值特征值。

通过上述过程，CRGGA 模块能够在多光谱通道存在空间响应不一致的情况下，自适应完成通道级空间对齐，并融合多方向上下文信息，从而生成空间一致性更强的特征表示。对齐后的特征将输入至主干网络的后续阶段，为后续跨模态特征融合与目标检测提供更加稳定且具有判别力的基础表征。

5.2.2 自适应采样多光谱融合方法(Adaptive Sampling Multispectral Fusion)

5.2.2.1 互补交叉注意力(Complementary Cross-Attention)

在多光谱溢油目标检测任务中，可见光图像主要反映地表物体的反射强度与纹理结构信息，能够提供较为丰富的空间细节。然而，在复杂陆地油田环境下，其成像结果易受到光照变化、阴影遮挡、土壤颜色相似性以及地表湿度变化等因素的干扰，导致溢油区域与背景之间的视觉对比度显著降低，判别特征甚至出现

弱化或缺失。相比之下，多光谱图像能够在特定波段（如近红外或短波红外）对原油表现出更为显著的反射或吸收差异，有利于增强溢油区域的可分性，但其受限于传感器空间分辨率和大气散射等因素，纹理与结构细节相对不足。因此，可见光与多光谱图像在信息表达上呈现出明显的互补特性，但同时也伴随着成像机理差异所引入的空间错位与语义不一致问题。若未能对这种互补性与不对齐性进行有效建模，简单的特征融合往往难以充分发挥多模态优势，从而限制目标检测性能的提升。

可见光与多光谱特征在成像机理和分布特性上存在显著差异，导致跨模态特征在空间对应关系和语义表达上难以直接对齐。为有效挖掘不同模态之间的对齐特征与互补信息，本文引入互补交叉注意力模块(Complementary Cross-Attention, CCA)，通过 Transformer 的跨模态交叉注意力机制，在特征层面显式建模两种模态之间的全局相关性，通过双向信息交互实现跨模态语义校准与互补特征增强。在前置空间对齐模块 CRGGA 初步缓解模态间几何错位的基础上，CCA 模块进一步自动发现并聚合具有高度相关性的跨模态对应特征，为后续检测头提供更加稳定且判别性更强的融合表示。




图 13 Complementary Cross-Attention

为提升跨模态注意力建模的稳定性与有效性，本文在跨模态交叉注意力计算之前，引入一种可变形采样对齐模块（Deformable Sampling Aligner, DSA），对两种模态特征进行空间对齐与结构化降采样处理。可见光模态与多光谱模态的特

征表示分别为 $x_{rgb} \in \mathbb{R}^{C \times H \times W}$ 及光谱特征图 $x_{ms} \in \mathbb{R}^{C \times H \times W}$ 在特征层面建立跨模态关联，首先分别对两种模态特征生成查询（Query）、键（Key）和值（Value）描述子。具体而言，采用 1×1 卷积对输入特征进行线性映射，并二维特征图重塑为序列形式，其生成过程可表示为

$$\begin{aligned} q_{rgb} &= \mathcal{R}(W_{rgb}^q * x_{rgb}), q_{ir} = \mathcal{R}(W_{ir}^q * x_{ir}), \\ k_{rgb} &= \mathcal{R}(W_{rgb}^k * x_{rgb}), k_{ir} = \mathcal{R}(W_{ir}^k * x_{ir}), \\ v_{rgb} &= \mathcal{R}(W_{rgb}^v * x_{rgb}), v_{ir} = \mathcal{R}(W_{ir}^v * x_{ir}), \end{aligned} \quad (5-12)$$

其中 W^q 、 W^k 和 W^v 表示对应的 1×1 卷积参数， $*$ 为卷积运算， $\mathcal{R}(\cdot)$ 表示将特征图从 $\mathbb{R}^{C \times H \times W}$ 重塑为 $\mathbb{R}^{HW \times C}$ 。

由于 RGB 与多光谱特征在统计分布上存在显著差异，若直接计算跨模态相似度，容易受到模态偏差的影响。从而削弱注意力权重的可靠性。为缓解上述问题，CCA 模块在特征交互前引入模态归一化（Modality Normalization）操作，将一种模态的特征分布映射至另一模态的统计空间，其过程表示为：

$$\tilde{x}_{rgb/ms} = \frac{x_{rgb/ms} - \mu}{\sigma + \epsilon} \quad (5-13)$$

其中 μ, σ 为通道维度的均值与标准差， ϵ 为数值稳定性项。计算好两个模态的统计量后，利用卷积网络预测可学习的尺度参数与偏置参数：

$$\begin{aligned} \beta_{ms} &= W_b * \text{ReLU}(W_d * x_{rgb}) + \mu_{rgb}, \\ \gamma_{ms} &= W_g * \text{ReLU}(W_d * x_{rgb}) + \sigma_{rgb}, \end{aligned} \quad (5-14)$$

其中 W_b 、 W_g 和 W_d 表示 3×3 卷积核。最终，通过尺度与偏置重映射得到分布对齐后的多光谱特征：

$$\hat{x}_{ms} = \tilde{x}_{ms} \cdot \gamma_{ms} + \beta_{ms} \quad (5-15)$$

可见光特征的模态归一化过程与之对称。经归一化处理后的特征用于生成查询描述子，从而有效减小模态分布差异对跨模态相似度计算的干扰。

在完成特征描述子构建后，CCA 模块通过跨模态交叉注意力机制显式建模 RGB 与多光谱特征之间的对应关系。具体而言，将一种模态的查询描述子与另一种模态的键描述子进行内积运算，构建跨模态相关性矩阵：

$$\begin{aligned} \tilde{M}_{rgb} &= \text{MatMul}(q_{ms}, k_{rgb}^T) / \sqrt{d} \\ \tilde{M}_{ms} &= \text{MatMul}(q_{rgb}, k_{ms}^T) / \sqrt{d} \end{aligned} \quad (5-16)$$

其中 d 表示特征维度， $\sqrt{d}$ 为缩放因子用于稳定梯度传播。随后，通过

softmax 函数对相关性矩阵进行归一化，得到跨模态相似度权重：

$$\begin{aligned} M_{rgb} &= \text{Softmax}(\tilde{M}_{rgb}), \\ M_{ms} &= \text{Softmax}(\tilde{M}_{ms}), \end{aligned} \quad (5-17)$$

其中 softmax 在列方向进行归一化，使每个特征位置在另一模态中的匹配权重之和为 1。上述相似度矩阵刻画了不同模态特征在空间维度上的对应关系，高权重位置表示跨模态对齐程度较高的特征点。

在获得跨模态相关性权重后，CCA 模块进一步采用 Soft Attention 进行跨模态特征融合。通过将相似度矩阵与对应模态的值描述子进行加权求和，聚合来自另一模态的上下文信息：

$$\tilde{y}_{rgb} = M_{rgb} v_{rgb}, \tilde{y}_{ms} = M_{ms} v_{ms} \quad (5-18)$$

随后，将融合后的特征序列 $\tilde{y} \in \mathbb{R}^{HW \times C}$ 回二维特征图形式，并通过卷积层映射至原始特征空间，得到最终的跨模态增强特征：

$$\begin{aligned} y_{rgb} &= W_m * \mathcal{R}(\tilde{y}_{rgb}), \\ y_{ms} &= W_n * \mathcal{R}(\tilde{y}_{ms}), \end{aligned} \quad (5-19)$$

其中， W_m 与 W_n 为卷积映射参数。

5.2.2.2 可变形采样对齐(Deformable Sampling Aligner)

CCA 模块通过跨模态交叉注意力机制在特征层面显式建模可见光与多光谱信息之间的对应关系，实现了跨模态语义交互与互补特征增强。然而，上述注意力建模依赖于不同模态特征在空间层面具有较为准确的对应关系。若模态间存在显著几何偏移或视角差异，跨模态相似度计算的可靠性将受到影响。此外，其核心计算过程依赖于高维特征序列之间的大规模矩阵乘法，在高分辨率特征输入下将带来显著的计算和存储开销。尤其是在 CCA 模块中，跨模态相关性矩阵的规模与特征空间分辨率呈平方关系增长，直接限制了模型在实际检测任务中的可扩展性与工程可行性。

为此，本文在 CCA 模块之前引入一种可变形采样对齐模块（Deformable Sampling Alignment, DSA）作为 CCA 的前置优化结构，旨在缓解可见光与多光谱图像在成像视角、阵列布局及传感器位置差异等因素作用下产生的空间错位问题，同时通过对输入特征进行结构化下采样，在显著降低计算复杂度的同时，尽可能保留跨模态对齐特征，为后续交叉注意力建模提供更加紧凑且有效的输入表

示。




图 14 Deformable Sampling Aligner

在进行特征降采样之前，DSA 模块先对两种模态之间的粗略空间偏移进行预测，并依据该偏移关系对特征进行自适应采样，从而避免简单均匀采样导致的对齐特征丢失问题。基于这一思想，DSA 模块借鉴可变形卷积的建模方式，通过学习空间偏移量引导跨模态特征的动态采样。

设 DSA 模块的输入为可见光特征 $x_{rgb} \in \mathbb{R}^{C \times H \times W}$ ，及多光谱特征 $x_{ms} \in \mathbb{R}^{C \times H \times W}$ ，模块位于 CCA 之前，用于对输入特征进行预处理。首先，将两种模态特征在通道维度上进行拼接，得到联合特征表表示

$$x_{cat} = \text{Concat}(x_{rgb}, x_{ms}) \in \mathbb{R}^{2C \times H \times W} \quad (5-20)$$

通过一个 1×1 卷积对通道维度进行压缩，得到用于偏移预测的中间特征图

$$x_d = W_c * x_{cat} \in \mathbb{R}^{C \times H \times W} \quad (5-21)$$

其中 W_c 表示通道压缩卷积核。为简化符号表示，下文省略批量维度。在获得中间特征后，DSA 模块引入一个偏移预测头 $f_d(\cdot)$ ，该网络由两层卷积模块及 GeLU 激活函数构成，用于学习两种模态特征之间的空间偏移关系。考虑到训练过程中预测偏移可能出现不稳定波动，本文采用双曲正切函数对偏移幅度进行约束，并通过尺度因子进行放缩，最终得到跨模态特征偏移场：

$$\Delta p = 2 \cdot \tanh(f_d(x_d)) \quad (5-22)$$

其中 $\Delta p \in \mathbb{R}^{H \times W \times 2}$ 别表示水平方向与垂直方向的空间偏移量。

在特征采样阶段，首先构建规则的参考采样网格。设采样步长为 s ，则下采样后的特征空间尺寸为

$$H_s = \frac{H}{s}, W_s = \frac{W}{s} \quad (5-23)$$

由此生成可见光与红外模态的参考采样点网格 $p_{rgb} \in \mathbb{R}^{H_s \times W_s \times 2}$ ， $p_{ms} \in \mathbb{R}^{H_s \times W_s \times 2}$

样点随后被归一化至区间 $[-1,+1]$ ，其中 $(-1,-1)$ 表示特征图左上角位置， $(+1,+1)$ 表示右下角位置。

在预测得到跨模态偏移场后，DSA 模块利用双线性插值采样函数 $\phi(\cdot; \cdot)$ ，分别从两种模态特征中提取自适应采样特征。具体而言，可见光模态的采样位置由参考网格与预测偏移共同决定，而红外模态仅采用规则网格采样，其过程可表示为：

$$\begin{aligned}\bar{x}_{rgb} &= \phi(x_{rgb}; p_{rgb} + \Delta p), \\ \bar{x}_{ms} &= \phi(x_{ms}; p_{ms})\end{aligned}\tag{5-24}$$

通过上述操作，得到下采样后的跨模态特征表示

$$\begin{aligned}\bar{x}_{rgb} &\in \mathbb{R}^{C \times H_s \times W_s}, \\ \bar{x}_{ms} &\in \mathbb{R}^{C \times H_s \times W_s}\end{aligned}\tag{5-25}$$

在引入 DSA 模块后，CCA 中式(5-12)的维度变为 $\mathbb{R}^{HW \times C}$ ，式(5-19) 维度变为 $\mathbb{R}^{H_s W_s \times C}$ ，从而显著降低跨模态相关性矩阵的规模与计算复杂度。同时，为保证 CCA 模块输出特征与主干网络特征尺寸一致，CCA 中用于输出映射的卷积层被替换为步长为 1×1 反卷积操作，使增强后的特征能够恢复至原始空间分辨率并无缝回馈至主干网络。

通过上述自适应特征采样与粗对齐建模，DSA 模块在有效控制计算开销的同时，尽可能保留跨模态对齐特征，为后续 CCA 模块的精细跨模态建模提供了高质量、低冗余的输入特征表示。

5.3 实验设计

5.3.1 实验数据集

在多光谱目标检测实验中，为全面验证所提出方法在真实工程场景与标准公开基准上的有效性与泛化能力，本文选取了三类具有代表性的数据集开展实验，包括：第三章构建的无人机多光谱油田漏油检测数据集，以及两个公开的高光谱目标检测数据集 HOD3K^[41] 和 HOD-1^[73]。不同数据集在成像方式、光谱维度、场景复杂度和目标类型等方面存在显著差异，有助于从多角度评估模型性能。

首先，本文自建的无人机多光谱油田漏油数据集来源于真实陆地油田环境，包含 RGB 通道及 7 个近可见-近红外多光谱通道，具有明确的工程应用背景和

较强的场景复杂性。该数据集目标以原油溢出区域为核心，同时包含多类易混淆地物，样本规模相对有限，更贴近实际小样本检测场景，主要用于验证模型在真实复杂环境下的实用性和鲁棒性。

其次，HOD3K 数据集是面向目标级高光谱检测任务的公开基准之一，数据由快照式高光谱相机采集，覆盖从可见光到近红外的 16 个光谱通道。该数据集包含校园、道路及居民区等多种自然场景，目标类型丰富，如行人、车辆和自行车等，具有较高的场景多样性和背景复杂度。为保证实验对比的公平性，本文沿用原始数据集的划分策略，将数据按 7:1:2 的比例划分为训练集、验证集和测试集，并仅在训练集上进行模型训练，在测试集上进行性能评估。HOD3K 数据集主要用于验证模型在多目标、多场景条件下对多光谱信息的综合建模能力。

此外，HOD-1 数据集是较早面向目标级高光谱目标检测任务构建的数据集，采用推扫式高光谱相机采集，单幅图像包含 96 个连续光谱通道。该数据集通过在真实场景中布置不同物体构建检测场景，并进一步引入“伪伪装”场景，即将真实场景显示在平板设备上后再由高光谱相机重新采集，从而形成具有强背景干扰的目标检测样本。HOD-1 数据集共包含 1657 幅高光谱图像，目标类别共 8 类，平均每幅图像包含多个目标实例。数据集同时提供与高光谱图像空间分辨率一致的 RGB 对照数据，使其成为验证光谱信息有效性的重要实验平台。本文沿用其官方的训练-测试划分方式（8:2），用于评估模型在高光谱维度下对弱可见特征目标的检测能力。

综合来看，自建油田多光谱数据集强调真实工程场景与小样本条件，HOD3K 数据集侧重多场景与多目标条件下的泛化能力评估，而 HOD-1 数据集则突出高光谱信息在复杂背景和伪伪装场景中的判别优势。通过在上述三类数据集上的联合实验，可以较为全面地验证本文所提出多光谱融合目标检测模型在不同光谱维度、成像方式和应用场景下的适应性与有效性。

5.3.2 评价指标

为客观、全面地评估多光谱目标检测模型在不同数据集上的检测性能，本文从检测准确性、召回能力及二者的综合表现等多个维度对模型进行定量分析。具体选取精确率（Precision）、召回率（Recall）、F1-score 以及平均精度均值（mean Average Precision, mAP）作为评价指标。其中，mAP 分别在交并比（Intersection

over Union, IoU) 阈值为 0.5 以及 0.5–0.95 区间内进行统计, 以全面刻画模型在不同定位精度要求下的检测性能。

1. 精确率与召回率

在目标检测任务中, 模型的预测结果通常可划分为真阳性 (True Positive, TP)、假阳性 (False Positive, FP) 和假阴性 (False Negative, FN)。基于上述定义, 精确率与召回率分别用于衡量检测结果的准确性与完整性, 其计算公式如下:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (5-26)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (5-27)$$

其中, 精确率反映模型预测为目标的检测结果中真实目标所占的比例, 体现模型对误检的抑制能力; 召回率则表示所有真实目标中被模型成功检测到的比例, 体现模型对漏检的敏感程度。在实际应用中, 精确率与召回率往往存在一定的权衡关系, 单一指标难以全面反映模型的整体检测性能。

2. F1-score

为综合衡量模型在精确率与召回率之间的平衡性能, 本文进一步引入 F1-score 指标。F1-score 定义为精确率与召回率的调和平均, 其计算公式为:

$$\text{F1-score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (5-28)$$

当精确率或召回率中任一指标较低时, F1-score 将显著下降, 因此该指标能够较为严格地反映模型在检测准确性与完整性之间的综合表现, 尤其适用于类别分布不均衡或小目标检测等复杂场景。

第六章 (3) 平均精度 (Average Precision, AP)

在目标检测评估中, 平均精度 (AP) 用于衡量模型在不同召回率水平下的整体检测性能。首先, 通过预测边界框与真实标注边界框之间的交并比 (IoU) 判断检测结果是否为真阳性, 其定义为:

$$\text{IoU} = \frac{B_p \cap B_{gt}}{B_p \cup B_{gt}}$$

其中, B_p 表示预测边界框, B_{gt} 表示真实边界框。当 IoU 大于预设阈值时, 预测结果被视为一次正确检测。

在此基础上, 将所有检测结果按照置信度从高到低排序, 可获得不同置信度阈值下的精确率–召回率 (Precision–Recall, P–R) 曲线。平均精度 AP 定义为

该 P-R 曲线下的面积，形式化表示为：

$$AP = \int_0^1 P(R) dR$$

其中， $P(R)$ 表示在召回率为 R 时对应的精确率。

第七章 （4）mAP@0.5 与 mAP@0.5:0.95

为进一步评估模型在不同目标定位精度要求下的检测性能，本文采用两种常用的 mAP 指标。

mAP@0.5 指在 IoU 阈值固定为 0.5 的条件下，对所有类别的 AP 取算术平均，其定义为：

$$mAP_{IoU=0.5} = \frac{1}{C} \sum_{c=1}^C AP_c (IoU = 0.5)$$

其中， C 表示目标类别总数， AP_c 表示第 c 类目标在 IoU 阈值为 0.5 时的平均精度。该指标对目标边界框的定位精度要求相对宽松，常用于衡量模型的基础检测能力。

mAP@0.5:0.95 则在 IoU 阈值从 0.5 到 0.95、步长为 0.05 的多个阈值条件下分别计算 AP，并对所有类别及所有 IoU 阈值进行平均，其计算形式为：

$$mAP_{IoU \in [0.5, 0.95]} = \frac{1}{C} \sum_{c=1}^C \frac{1}{T} \sum_{t=1}^T AP_c (IoU_t) \quad (5-29)$$

其中，

$$IoU_t = 0.5 + 0.05 \times (t - 1), t = 1, 2, \dots, 10 \quad (5-30)$$

该指标对目标边界框的定位精度要求更为严格，能够更加真实、全面地反映模型在高精度检测任务中的综合性能。

第八章 （5）指标选取说明

综上所述，Precision、Recall 及 F1-score 主要用于刻画模型在固定阈值条件下的检测准确性与完整性，而 mAP@0.5 与 mAP@0.5:0.95 则从整体检测性能角度评估模型在不同定位精度要求下的表现。本文在后续实验分析中将结合上述多项评价指标，对所提出的多光谱融合目标检测模型进行系统对比与深入讨论。

。

8.1.1 实验基本环境

在本文的实验中，为保证结果的一致性和可重复性，所有模型均在统一的环境下进行训练和测试。实验环境的硬件设备配置为 NVIDIA GeForce RTX 4090 GPU 和 Intel Xeon Gold 6430 处理器，内存为 256GB。软件环境配置操作系统为 Linux，编程语言为 Python3.11，深度学习框架为 PyTorch，Torch 版本为 2.9.1，使用 CUDA 的版本为 CUDA 12.9。

本章实验中，以在 ImageNet 上进行过预训练的 ResNet-50 作为主干网络。模型的输入图像尺寸为 640×640 ，并进行了数据增强处理(包括随机裁剪、翻转、颜色抖动等)，批次大小为 8，优化器为 Adam，学习率初始值为 0.0005，并采用指数衰减策略，训练轮数为 120 epoch。

8.2 实验结果与分析

8. 2. 1 XXXXXXXXX

表 3 石油多光谱遥感数据集结果							
Algorithm	Channel	Precision	Recall	mAP@0.5	mAP@0.5:0.95	Params(M)	GFLOPS
RT-DETR	3	0.812	0.717	0.794	0.412	61	191.4
Mamba-YOLO [67]	3	0.778	0.689	0.769	0.406	5.98	13.6
FCOS [68]	3	0.723	0.721	0.764	0.397	32.11	161.21
CenterNet [69]	3	0.585	0.41	0.502	0.247	32.6	70.21
RetinaNet [70]	3	0.737	0.475	0.562	0.253	37.96	170
Faster RCNN	3	0.34	0.845	0.654	0.31	137	370
YOLOv3 [71]	3	0.799	0.655	0.756	0.405	12.13	19

YOLOv5	3	0.724	0.664	0.786	0.43	2.51	7.2
YOLOv6 [72]	3	0.778	0.683	0.775	0.448	4.23	11.9
YOLOv8	3	0.782	0.675	0.789	0.432	3	8.2
YOLOv9t	3	0.784	0.713	0.766	0.429	2	7.9
YOLOv10n	3	0.733	0.682	0.735	0.409	2.7	8.4
YOLOv11	3	0.742	0.635	0.766	0.446	2.59	6.4
Ours							
Ours							

表 4 HOD3K 数据集

Algorithm	Channel	Precision	Recall	mAP@0.5	mAP@0.5:0.95	Params(M)	GFLOPS
RT-DETR	3	0.812	0.717	0.794	0.412	61	191.4
Mamba-YOLO [67]	3	0.778	0.689	0.769	0.406	5.98	13.6
FCOS [68]	3	0.723	0.721	0.764	0.397	32.11	161.21
CenterNet [69]	3	0.585	0.41	0.502	0.247	32.6	70.21
RetinaNet [70]	3	0.737	0.475	0.562	0.253	37.96	170
Faster RCNN	3	0.34	0.845	0.654	0.31	137	370
YOLOv3 [71]	3	0.799	0.655	0.756	0.405	12.13	19
YOLOv5	3	0.724	0.664	0.786	0.43	2.51	7.2
YOLOv6 [72]	3	0.778	0.683	0.775	0.448	4.23	11.9
YOLOv8	3	0.782	0.675	0.789	0.432	3	8.2
YOLOv9t	3	0.784	0.713	0.766	0.429	2	7.9
YOLOv10n	3	0.733	0.682	0.735	0.409	2.7	8.4
YOLOv11	3	0.742	0.635	0.766	0.446	2.59	6.4
Ours							
Ours							

表 5 HOD1 数据集

Algorithm	Channel	Precision	Recall	mAP@0.5	mAP@0.5:0.95	Params(M)	GFLOPS
RT-DETR	3	0.812	0.717	0.794	0.412	61	191.4
Mamba-YOLO	3	0.778	0.689	0.769	0.406	5.98	13.6

[67]							
FCOS [68]	3	0.723	0.721	0.764	0.397	32.11	161.21
CenterNet [69]	3	0.585	0.41	0.502	0.247	32.6	70.21
RetinaNet [70]	3	0.737	0.475	0.562	0.253	37.96	170
Faster RCNN	3	0.34	0.845	0.654	0.31	137	370
YOLOv3 [71]	3	0.799	0.655	0.756	0.405	12.13	19
YOLOv5	3	0.724	0.664	0.786	0.43	2.51	7.2
YOLOv6 [72]	3	0.778	0.683	0.775	0.448	4.23	11.9
YOLOv8	3	0.782	0.675	0.789	0.432	3	8.2
YOLOv9t	3	0.784	0.713	0.766	0.429	2	7.9
YOLOv10n	3	0.733	0.682	0.735	0.409	2.7	8.4
YOLOv11	3	0.742	0.635	0.766	0.446	2.59	6.4
Ours							
Ours							

8.3 本章小节

第九章 总结与展望

参考文献

- [1] Li P, Cai Q, Lin W, et al. Offshore oil spill response practices and emerging challenges[J]. Marine Pollution Bulletin, 2016, 110(1): 6-27.
- [2] Environmental disaster in the northeast coast of Brazil: forensic geochemistry in the identification of the source of the oily material - ScienceDirect[EB/OL]. [2025-12-28]. <https://www.sciencedirect.com/science/article/pii/S0025326X20307153>.
- [3] Al-Ruzouq R, Gibril M B A, Shanableh A, et al. Sensors, features, and machine learning for oil spill detection and monitoring: a review[J]. Remote Sensing, 2020, 12(20): 3338.
- [4] Zhang Y, Xing J, Chen W, et al. A novel YOLOv11-driven deep learning algorithm for UAV multispectral oil spill detection in inland lakes[J]. Journal of King Saud University Computer and Information Sciences, 2025, 37(5): 108.
- [5] Golcarenenji G, Amer E, Mohasseb A, et al. Explainable oil spill detection using UAV imagery[C]//2025 International Mobile, Intelligent, and Ubiquitous Computing Conference (MIUCC). 2025: 129-134.
- [6] Paneru S, Jeelani I. Computer vision applications in construction: Current state, opportunities & challenges[J]. Automation in Construction, 2021, 132: 103940.
- [7] Janai J, Güney F, Behl A, et al. Computer vision for autonomous vehicles: problems, datasets and state of the art[J]. Foundations and Trends in Computer Graphics and Vision, 2020, 12(1-3): 1-308.
- [8] Cazzato D, Cimarelli C, Sanchez-Lopez J L, et al. A survey of computer vision methods for 2D object detection from unmanned aerial vehicles[J]. Journal of Imaging, 2020, 6(8): 78.
- [9] Xie M, Li Y, Zhang Z, et al. Remote sensing of the oil spills caused by ships: a review[J]. Marine Pollution Bulletin, 2025, 214: 117754.
- [10] Zou Z, Chen K, Shi Z, et al. Object detection in 20 years: a survey[J]. Proceedings of the IEEE, 2023, 111(3): 257-276.
- [11] Liu L, Ouyang W, Wang X, et al. Deep learning for generic object detection: a survey[J]. International Journal of Computer Vision, 2019, 128(2): 261-318.
- [12] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. International Journal of Computer Vision, 2004, 60(2): 91-110.
- [13] Ojala T, Pietikainen M, Maenpaa T. Multiresolution gray-scale and rotation invariant texture classification with local binary patterns[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2002, 24(7): 971-987.
- [14] Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]//2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05): Vol. 1. 2005: 886-893 vol. 1.
- [15] Cortes C, Vapnik V. Support-vector networks[J]. Machine Learning, 1995, 20(3): 273-297.
- [16] Freund Y, Schapire R E. A decision-theoretic generalization of on-line learning and an application to boosting[J]. Journal of Computer and System Sciences, 1997, 55(1): 119-139.
- [17] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]//Advances in Neural Information Processing Systems: Vol. 25. Curran Associates, Inc., 2012.
- [18] Deng J, Dong W, Socher R, et al. ImageNet: a large-scale hierarchical image database[C]//2009 IEEE Conference on Computer Vision and Pattern Recognition. 2009: 248-255.
- [19] Girshick R, Donahue J, Darrell T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]. [2026].
- [20] Girshick R. Fast R-CNN[C]. [2026].
- [21] Ren S, He K, Girshick R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.

- [22] He K, Gkioxari G, Dollar P, et al. Mask R-CNN[C]. 2017.
- [23] Redmon J, Divvala S, Girshick R, et al. You only look once: unified, real-time object detection[A]. arXiv, 2016.
- [24] Liu W, Anguelov D, Erhan D, et al. SSD: single shot MultiBox detector[C]. 2016.
- [25] Vaswani A, Shazeer N, Parmar N, et al. Attention is All you Need[C]//Advances in Neural Information Processing Systems: Vol. 30. Curran Associates, Inc., 2017.
- [26] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: transformers for image recognition at scale[A]. arXiv, 2021.
- [27] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers[A]. arXiv, 2020.
- [28] Zhu X, Su W, Lu L, et al. Deformable DETR: deformable transformers for end-to-end object detection[A]. arXiv, 2021.
- [29] Meng D, Chen X, Fan Z, et al. Conditional DETR for fast training convergence[A]. arXiv, 2023.
- [30] Liu S, Li F, Zhang H, et al. DAB-DETR: dynamic anchor boxes are better queries for DETR[A]. arXiv, 2022.
- [31] Zhao Y, Lv W, Xu S, et al. DETRs beat YOLOs on real-time object detection[A]. arXiv, 2024.
- [32] Gallagher J E, Oughton E J. Surveying you only look once (YOLO) multispectral object detection advancements, applications, and challenges[J]. IEEE Access, 2025, 13: 7366-7395.
- [33] Hwang S, Park J, Kim N, et al. Multispectral pedestrian detection: benchmark dataset and baseline[C]//2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2015: 1037-1045.
- [34] Wagner J, Fischer V, Herman M, et al. Multispectral pedestrian detection using deep fusion convolutional neural networks[J]. Computational Intelligence, 2016.
- [35] Liu J, Zhang S, Wang S, et al. Multispectral deep neural networks for pedestrian detection[A]. arXiv, 2016.
- [36] König D, Adam M, Jarvers C, et al. Fully convolutional region proposal networks for multispectral person detection[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). 2017: 243-250.
- [37] Li C, Song D, Tong R, et al. Multispectral pedestrian detection via simultaneous detection and segmentation[A]. arXiv, 2018.
- [38] Zhang L, Liu Z, Zhang S, et al. Cross-modality interactive attention network for multispectral pedestrian detection[J]. Information Fusion, 2019, 50: 20-29.
- [39] Yang X, Qian Y, Zhu H, et al. BAANet: learning Bi-directional adaptive attention gates for multispectral pedestrian detection[C]//2022 International Conference on Robotics and Automation (ICRA). 2022: 2920-2926.
- [40] Yuan M, Wei X. C²Former: calibrated and complementary transformer for RGB-infrared object detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-12.
- [41] He X, Tang C, Liu X, et al. Object detection in hyperspectral image via unified spectral-spatial feature aggregation[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-13.
- [42] Li W, Yuan F, Zhang H, et al. Hyperspectral Object Detection Based on Spatial-Spectral Fusion and Visual Mamba[J]. Remote Sensing, 2024, 16(23): 4482.
- [43] Yang J, Ma Y, Hu Y, et al. Decision fusion of deep learning and shallow learning for marine oil spill detection[J]. Remote Sensing, 2022, 14(3): 666.
- [44] Zhu Q, Zhang Y, Li Z, et al. Oil spill contextual and boundary-supervised detection network based on marine SAR images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-10.
- [45] Yang J, Hu Y, Ma Y, et al. Combined retrieval of oil film thickness using hyperspectral and thermal infrared remote sensing[J]. Remote Sensing, 2023, 15(22): 5415.
- [46] Zhang N, Yang J, Liu S, et al. Hyperspectral remote sensing identification of marine oil spills and emulsions using feature bands and double-branch dual-attention mechanism network[J]. Journal of Oceanology and Limnology, 2024, 42(3): 728-743.
- [47] Hu H, Huang Y, Da X, et al. Optimization of energy utilization in cognitive UAV systems[J]. IEEE Sensors Journal, 2021, 21(3): 3933-3943.
- [48] Nahiyoos S A, Ren Z, Wei P, et al. Recent development trends in plant protection UAVs: a

- p>journey from conventional practices to cutting-edge technologies—a comprehensive review[J].
- Drones*
- , 2024, 8(9): 457.
- [49] SUN Gang H W. Advances in UAV-based multispectral remote sensing applications[J]. *Nongye Jixie Xuebao/Transactions of the Chinese Society of Agricultural Machinery*, 2021, 49(3).
- [50] Tadmor E, Nevet A, Yahav G, et al. Dynamic multispectral imaging using the vertical overflow drain structure[J]. *IEEE Sensors Journal*, 2015, 15(7): 3967-3972.
- [51] Barabanova E A, Vytovtov K A, Gladkikh T Ya, et al. Environmental Monitoring of Water Surface Pollution in the Visible Range by Using UAVs[J]. *Journal of Communications Technology and Electronics*, 2023, 68(S3): S388-S392.
- [52] Lennon M, Babichenko S, Thomas N, et al. Detection and mapping of oil slicks in the sea by combined use of hyperspectral imagery and laser-induced fluorescence[J].
- [53] Shao J, Li G, Zhang Z, et al. Measurements of diffusion characteristics of hydroxyl radical with laser-induced fluorescence at high temperature[J]. *Optics Communications*, 2021, 488: 126810.
- [54] Yin S, Sun F, Liu W, et al. Remote identification of oil films on water via laser-induced fluorescence LiDAR[J]. *IEEE Sensors Journal*, 2023, 23(12): 13671-13679.
- [55] Sun L, Zhang Y, Ouyang C, et al. A portable UAV-based laser-induced fluorescence lidar system for oil pollution and aquatic environment monitoring[J]. *Optics Communications*, 2023, 527: 128914.
- [56] Nasayreh A, Jaradat A S, Gharaibeh H, et al. Jordanian banknote data recognition: a CNN-based approach with attention mechanism[J]. *Journal of King Saud University - Computer and Information Sciences*, 2024, 36(4): 102038.
- [57] Rutoh E K, Zhi Guang Q, Bahadar N, et al. GAIR-U-net: 3D guided attention inception residual u-net for brain tumor segmentation using multimodal MRI images[J]. *Journal of King Saud University - Computer and Information Sciences*, 2024, 36(6): 102086.
- [58] Chen Z, Li F, Diao Y, et al. Knowledge-embedded multi-layer collaborative adaptive fusion network: addressing challenges in foggy conditions and complex imaging[J]. *Journal of King Saud University - Computer and Information Sciences*, 2024, 36(10): 102230.
- [59] Tao J, Wei J, Zhou H, et al. Enhanced prediction model of short-term sea surface wind speed: a multiscale feature extraction and selection approach coupled with deep learning technique[J]. *Journal of King Saud University - Computer and Information Sciences*, 2024, 36(8): 102192.
- [60] Wang C Y, Yeh I H, Mark Liao H Y. YOLOv9: learning what you want to learn using programmable gradient information[C]. 2024.
- [61] Fang J, Chen X, Zhao J, et al. A scalable attention network for lightweight image super-resolution[J]. *Journal of King Saud University - Computer and Information Sciences*, 2024, 36(8): 102185.
- [62] Xu S, Zheng S, Xu W, et al. HCF-net: hierarchical context fusion network for infrared small object detection[C]//2024 IEEE International Conference on Multimedia and Expo (ICME). Niagara Falls, ON, Canada: IEEE, 2024: 1-6.
- [63] Agarap A F. Deep learning using rectified linear units (ReLU)[EB/OL]. [2026-01-08]. <https://arxiv.org/abs/1803.08375v2>.
- [64] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[A]. *arXiv*, 2015.
- [65] Hou Z, Yang C, Sun Y, et al. An object detection algorithm based on infrared-visible dual modal feature fusion[J]. *Infrared Physics & Technology*, 2024, 137: 105107.
- [66] Zhang J, Cao M, Xie W, et al. E2E-MFD: towards end-to-end synchronous multimodal fusion detection[J]. [2026].
- [67] Zeng Y, Liang T, Jin Y, et al. MMI-det: exploring multi-modal integration for visible and infrared object detection[J]. *IEEE Transactions on Circuits and Systems for Video Technology*, 2024, 34(11): 11198-11213.
- [68] Meng F, Hong A, Tang H, et al. FQDNet: a fusion-enhanced quad-head network for RGB-infrared object detection[J]. *Remote Sensing*, 2025, 17(6): 1095.
- [69] Fu H, Liu H, Yuan J, et al. YOLO-adaptor: a fast adaptive one-stage detector for non-aligned visible-infrared object detection[J]. *IEEE Transactions on Intelligent Vehicles*, 2024, 9(11):

7070-7083.

- [70] Zhang L, Liu Z, Zhu X, et al. Weakly aligned feature fusion for multimodal object detection[J]. IEEE Transactions on Neural Networks and Learning Systems, 2025, 36(3): 4145-4159.
- [71] Hu Z, Li Y. A study on the service design of self-health management for adolescents with asthma based on persuasive technology[C]. 2023.
- [72] Dahai N, Sheng Z. An object detection algorithm based on decision-level fusion of visible and infrared images[J]. Infrared Technology , 2023, Vol. 45, Issue 3, Pages: 282-291, 2023.
- [73] Yan L, Zhao M, Wang X, et al. Object detection in hyperspectral images[J]. IEEE Signal Processing Letters, 2021, 28: 508-512.

附录 AXXXXXX

A. 1XXXXXXXX

XX
XXX.....

表 A-1XXXXXXXX

A. 2XXXXXXXX

XX
XXX.....

图 A-1XXXXXXXX

致谢

XX
XX.....

攻读硕士学位期间的科研成果

学术论文

- [1]PEIS,HUANGLL,LIG,etal.MagneticRamanContinuuminSingle-Crystalline $\text{H}_3\text{LiIr}_2\text{O}_6$ [J].PhysicalReviewB,2020,101(20):201101(R). (SCI 收录,IDS 号为 LJ4UN,IF=3.575,对应学位论文 2.2 节和第 5 章)
- [2]XXX, XX. (已被 XX 期刊录用)

专著/译著 (无专著或译著时此项不必列出)

- [3]XXX, XX.
- [4]XXX, XX. (XXX 出版社, 预计出版时间为.....)

已获得及申请的专利 (无专利时此项不必列出)

- [5]XXX, XX.
- [6]XXX, XX.

研究报告 (无研究报告时此项不必列出)

- [7]XXX, XX.

其他研究成果 (无其他研究成果时此项不必列出)

- [8]XXX, XX.
- [9]XXX, XX.

深圳大学

指导教师对研究生学位论文的学术评语

研究生 姓名		论文题目			
学号		专业 (领域) 名称		学位级别	
对学位论文的学术评语（评价论文的学术水平和实用价值，论文有无新见解，论据是否充分、可靠，运用基础和专业理论、知识的实际能力，所体现的科研能力，论文写作是否严谨、科学，是否有学术不端行为，论文存在的主要缺点和问题等，是否达到学位论文的要求）：					
指导教师对学位论文的评阅结果： 指导教师（签名）： 日期： 年 月 日					

深圳大学研究生学位(毕业)论文
答辩委员会决议书

研究生姓名		论文题目			
学号		专业 (领域)名称		学位 级别	
论文答辩委员会出席名单	委员会成员	姓名	职称	工作单位	本人签名
	主席				
	委员				
		秘书			
	答辩日期	年月日			
答辩地点					

深圳大学研究生学位(毕业)论文
答辩委员会决议书

研究生姓名		论文题目			
学号		专业 (领域) 名称		学位级别	
答辩日期					
答辩委员会对学位论文及答辩情况的评语及明确的结论意见 (850 字以内):					
答辩 委员	表决项目		计票	结论	
	毕业论文(准予毕业)	通过		通过 ☐ 未通过 ☐	
		未通过			
	学位论文(建议授予学位)	同意		通过 ☐ 未通过 ☐	
		不同意			
	学位论文答辩不通过，允许其修改论文后重新申请一次答辩票。				
秘书（签名）： 主席（签名）：					